Contents

1 概率论的公理化 **5**

1.1 集合拓扑 5

1.2 测度 9

1.3 概率论的公理化 16

2 一元概率论 **21**

2.1 随机变量与分布 21

2.2 期望与方差 29

3 多元概率论 **37**

3.1 随机向量与分布 37

3.2 期望与协方差 44

3.3 大数定律 48

4 中心极限定理 **57**

4.1 特征函数理论 57

4.2 中心极限定理 61

5 问题 **67**

5.1 问题与解答 67

5.2 习题集 71

This page intentionally left blank.

Chapter 1

概率论的公理化

1.1 集合拓扑

Theorem 1.(De Morgan) 设 $A_n \subseteq X (n \in \mathbb{N}^*)$ 是一列子集, 则有

$$\bigcap_{n=1}^{\infty} A_n = X \setminus \bigcup_{n=1}^{\infty} (X \setminus A_n),$$

$$\bigcup_{n=1}^{\infty} A_n = X \setminus \bigcap_{n=1}^{\infty} (X \setminus A_n).$$

Proof. 设 $x \in \bigcap\limits_{n=1}^{\infty} A_n$, 则对任意 $n \in \mathbb{N}^*$, 有 $x \in A_n$, 于是 $x \notin X \setminus A_n$, 则 $x \notin \bigcup\limits_{n=1}^{\infty} (X \setminus A_n)$, 此即

$$x \in X \setminus \bigcup_{n=1}^{\infty} (X \setminus A_n).$$

再设

$$x \in X \setminus \bigcup_{n=1}^{\infty} (X \setminus A_n),$$

则对任意 $n \in \mathbb{N}^*$, 有 $x \notin X \setminus A_n$, 则有 $x \in A_n$, 进而 $x \in \bigcap\limits_{n=1}^{\infty} A_n$, 这就证明了

$$\bigcap_{n=1}^{\infty} A_n = X \setminus \bigcup_{n=1}^{\infty} (X \setminus A_n).$$

设 $x \in \bigcup\limits_{n=1}^{\infty} A_n$, 则存在一个 $n_0 \in \mathbb{N}^*$, 使得 $x \in A_{n_0}$, 于是 $x \notin X \setminus A_{n_0}$, 则 $x \notin \bigcap\limits_{n=1}^{\infty} (X \setminus A_n)$, 此即

$$x \in X \setminus \bigcap_{n=1}^{\infty} (X \setminus A_n).$$

再设

$$x \in X \setminus \bigcap_{n=1}^{\infty} (X \setminus A_n),$$

则存在一个 $n_0 \in \mathbb{N}^*$, 使得 $x \notin X \setminus A_{n_0}$, 则有 $x \in A_{n_0}$, 进而 $x \in \bigcup\limits_{n=1}^{\infty} A_n$, 这就证明了

$$\bigcup_{n=1}^{\infty} A_n = X \setminus \bigcap_{n=1}^{\infty} (X \setminus A_n).$$

□

Definition 1.(集合的单调性与单调极限) 设 $A_n \subseteq X (n \in \mathbb{N}^*)$ 是一列子集. 若 $A_n \subseteq A_{n+1}$ 对一切 $n \in \mathbb{N}^*$ 成立, 则称该集合列单调上升, 并称

$$\lim_{n\to\infty} A_n = \bigcup_{n=1}^{\infty} A_n$$

为该集合列的极限. 若 $A_n \supseteq A_{n+1}$ 对一切 $n \in \mathbb{N}^*$ 成立, 则称该集合列单调下降, 并称

$$\lim_{n\to\infty} A_n = \bigcap_{n=1}^{\infty} A_n$$

为该集合列的极限.

Definition 2.(集合列的上下极限) 设 $A_n \subseteq X (n \in \mathbb{N}^*)$ 是一列子集. 定义这列子集的上下极限为

$$\limsup_{n\to\infty} A_n = \lim_{m\to\infty} \bigcup_{n=m}^{\infty} A_n = \bigcap_{m=1}^{\infty} \bigcup_{n=m}^{\infty} A_n,$$

$$\liminf_{n\to\infty} A_n = \lim_{m\to\infty} \bigcap_{n=m}^{\infty} A_n = \bigcup_{m=1}^{\infty} \bigcap_{n=m}^{\infty} A_n.$$

Proposition 2. 设 $A_n \subseteq X (n \in \mathbb{N}^*)$ 是一列子集, 则

$$\liminf_{n\to\infty} A_n \subseteq \limsup_{n\to\infty} A_n.$$

Proof. 任取 $x \in \liminf_{n\to\infty} A_n$, 则存在某个 $m \in \mathbb{N}^*$, 使得 $x \in A_n$ 对一切 $n \geq m$ 都成立. 于是

$$x \in A_{\max\{k,m\}} \subseteq \bigcup_{n=k}^{\infty} A_n \implies x \in \bigcap_{k=1}^{\infty} \bigcup_{n=k}^{\infty} A_n = \limsup_{n\to\infty} A_n.$$

□

Definition 3.(集函数) 设 $\mathscr{F}$ 是一个集合族, $\mathbb{F}$ 是 (扩充的) 数系, 则一个映射 $\mu : \mathscr{F} \to \mathbb{F}$ 称为集函数.

Definition 4.(集函数的连续性) 设 $\mathscr{F}$ 是一个集合族, $\mu : \mathscr{F} \to \mathbb{F}$ 是集函数. 若对任意单调上升的集合列 $\{A_n\} \subseteq \mathscr{F}$, 都有

$$\mu\left(\lim_{n\to\infty} A_n\right) = \lim_{n\to\infty} \mu(A_n),$$

则称函数 μ 是 $\mathscr{F}$ 上的连续函数.

Definition 5.(集函数的可加性) 设 $\mathscr{F}$ 是一个集合族, $\mu:\mathscr{F}\to\mathbb{F}$ 是集函数. 若对任意两两交为空的子集列 $A_n\in\mathscr{F}(n\in\mathbb{N}^*)$, 都有

$$\mu\left(\bigcup_{k=1}^{n}A_k\right)=\sum_{k=1}^{n}\mu(A_k),$$

则称 μ 满足有限可加性. 若对任意两两交为空的子集列 $A_n\in\mathscr{F}(n\in\mathbb{N}^*)$, 都有

$$\mu\left(\bigcup_{n=1}^{\infty}A_n\right)=\sum_{n=1}^{\infty}\mu(A_n),$$

则称 μ 满足可列可加性.

Proposition 3. 设 $\mathscr{F}$ 是一个集合族, $\mu:\mathscr{F}\to\mathbb{F}$ 是集函数. 证明: μ 满足可列可加性的充要条件是 μ 连续且满足有限可加性.

Proof. (必要性) 取 $A_k=\emptyset(k>n)$ 即可推出有限可加性. 设 $\{A_n\}\subseteq\mathscr{F}$ 单调上升, 则

$$\lim_{n\to\infty}A_n=\left(\bigcup_{n=1}^{\infty}(A_{n+1}\setminus A_n)\right)\cup A_1.$$

根据可列可加性, 有

$$\begin{aligned}\mu\left(\lim_{n\to\infty}A_n\right)&=\mu\left(\left(\bigcup_{n=1}^{\infty}(A_{n+1}\setminus A_n)\right)\cup A_1\right)\\&=\sum_{n=1}^{\infty}\mu(A_{n+1}\setminus A_n)+\mu(A_1)\\&=\lim_{m\to\infty}\left(\sum_{n=1}^{m}\mu(A_{n+1}\setminus A_n)\right)+\mu(A_1)\\&=\lim_{m\to\infty}\left(\sum_{n=1}^{m}\mu(A_{n+1})-\sum_{n=1}^{m}\mu(A_n)+\mu(A_1)\right)\\&=\lim_{m\to\infty}\mu(A_{m+1})\\&=\lim_{n\to\infty}\mu(A_n).\end{aligned}$$

(充分性) 任取一个无穷集合列 $\{A_n\}$, 使得对于任意 $i,j\in\mathbb{N}^*$, 满足 $i\neq j$, 都有 $A_i\cap A_j=\emptyset$. 定义 $B_n=\bigcup_{k=1}^{n}A_n$, 则 $\{B_n\}$ 是一列单调上升的集合列. 根据连续性有

$$\mu\left(\lim_{n\to\infty}B_n\right)=\lim_{n\to\infty}\mu(B_n).$$

从而根据有限可加性有

$$\mu\left(\bigcup_{n=1}^{\infty}A_n\right)=\mu\left(\lim_{n\to\infty}B_n\right)=\lim_{n\to\infty}\mu(B_n)=\lim_{n\to\infty}\mu\left(\bigcup_{k=1}^{n}A_n\right)=\lim_{n\to\infty}\sum_{k=1}^{n}\mu(A_k).$$

这就证明了可列可加性

$$\mu\left(\bigcup_{n=1}^{\infty} A_n\right) = \sum_{k=1}^{\infty} \mu(A_k).$$

□

1.2 测度

Definition 6.(代数) 一个集合 X 上的代数是一个子集族 $\mathscr{F} \subseteq \mathcal{P}(X) := \{A \subseteq X\}$, 满足

1. (全集) $X \in \mathscr{F}$.
2. (补的封闭性) 若 $A \in \mathscr{F}$, 则 $X \setminus A \in \mathscr{F}$.
3. (并的封闭性) 若 $A_k \in \mathscr{F}(k = 1, 2, \ldots, n)$, 则
$$\bigcup_{k=1}^{n} A_k \in \mathscr{F}.$$

Definition 7.(σ-代数) 一个集合 X 上的 σ-代数是一个代数 $\mathscr{F} \subseteq \mathcal{P}(X)$, 满足并的封闭性, 即若 $A_n \in \mathscr{F}(n \in \mathbb{N}^*)$, 则
$$\bigcup_{n=1}^{\infty} A_n \in \mathscr{F}.$$
此时称 $(X, \mathscr{F})$ 是可测空间.

Definition 8.(生成 σ-代数) 设 $\mathscr{F} \subseteq \mathcal{P}(X)$ 是子集族, 定义 $\sigma(\mathscr{F}) \subseteq \mathcal{P}(X)$ 是最小的满足以下性质的集合 $\mathscr{E}$.

1. $\mathscr{F} \subseteq \mathscr{E} \subseteq \mathcal{P}(X)$.
2. 若 $A \in \mathscr{E}$, 则 $X \setminus A \in \mathscr{E}$.
3. 若 $A_n \in \mathscr{E}(n \in \mathbb{N}^*)$, 则
$$\bigcup_{n=1}^{\infty} A_n \in \mathscr{E}.$$

即 $\sigma(\mathscr{F})$ 定义为满足以上条件的 $\mathscr{E}$ 之交, 成为由 $\mathscr{F}$ 生成的 σ-代数.

Corollary 4. 设 $\mathscr{F}$ 是集合 X 上的 σ-代数, 则
$$\emptyset = X \setminus X \in \mathscr{F}.$$
若 $A_n \in \mathscr{F}(n \in \mathbb{N}^*)$, 则 $X \setminus A_n \in \mathscr{F}$, 进而
$$\bigcap_{n=1}^{\infty} A_n = X \setminus \bigcup_{n=1}^{\infty} (X \setminus A_n) \in \mathscr{F}.$$

Definition 9.(预测度与测度) 设 $\mathscr{F}$ 是 X 上的代数, $\mu : \mathscr{F} \to [0, +\infty]$ 是集函数, 满足

1. (空集) $\mu(\emptyset)=0$.
2. (可列可加性) 若 $A_n\in\mathscr{F}(n\in\mathbb{N}^*)$ 是一列子集, 满足对任意 $i,j\in\mathbb{N}^*$ 使得 $i\neq j$, 都有 $A_i\cap A_j=\emptyset$, 则
$$\mu\left(\bigcup_{n=1}^{\infty}A_n\right)=\sum_{n=1}^{\infty}\mu(A_n).$$

则称 μ 是 $\mathscr{F}$ 上的预测度. 当 $\mathscr{F}$ 是 X 上的 σ-代数时, 则称 μ 是 $\mathscr{F}$ 上的测度.

Remark. 当集合列 A_n 满足对任意 $i,j\in\mathbb{N}^*$ 使得 $i\neq j$, 都有 $A_i\cap A_j=\emptyset$, 也记
$$\sum_{n=1}^{\infty}A_n:=\bigcup_{n=1}^{\infty}A_n.$$

Corollary 5.(单调性) 设 $\mathscr{F}$ 是 X 上的 σ-代数, $\mu:\mathscr{F}\to[0,+\infty]$ 是测度. 若 $A_n\in\mathscr{F}(n\in\mathbb{N}^*)$ 是一列子集, 则
$$\mu\left(\bigcup_{n=1}^{\infty}A_n\right)\leq\sum_{n=1}^{\infty}\mu(A_n).$$

Proof. 定义
$$B_1=A_1,\quad B_{n+1}=\left\{x\in A_{n+1}\mid x\notin\bigcup_{k=1}^{n}A_k\right\}.$$
则任意两个 B_i,B_j 无交. 一方面显然有
$$B_n\subseteq\bigcup_{n=1}^{\infty}A_n\implies\bigcup_{n=1}^{\infty}B_n\subseteq\bigcup_{n=1}^{\infty}A_n.$$
另一方面, 设 x 在 A_n 的并集中, 则必在某些 A_k 中, 记下标最小者为 n_0, 则 $x\in B_{n_0}$, 进而在 B_n 的并集中. 根据可列可加性
$$\mu\left(\bigcup_{n=1}^{\infty}A_n\right)=\mu\left(\bigcup_{n=1}^{\infty}B_n\right)=\sum_{n=1}^{\infty}\mu(B_n).$$
依照定义, $B_n\subseteq A_n$, 根据有限可加性和非负性
$$\mu(B_n)+\mu(A_n\setminus B_n)=\mu(A_n)\implies\mu(B_n)\leq\mu(A_n).$$
代入得
$$\mu\left(\bigcup_{n=1}^{\infty}A_n\right)=\sum_{n=1}^{\infty}\mu(B_n)\leq\sum_{n=1}^{\infty}\mu(A_n).$$
□

Example 1.(计数测度) 对一个集合 X, 有 σ-代数 $\mathcal{P}(X)$, 则计数函数
$$\mathrm{card}:\mathscr{F}\to\mathbb{N}\cup\{\infty\}$$
是 $\mathcal{P}(X)$ 上的测度.

***Definition 10.(外测度)** 设 X 是集合, $\mu^*:\mathcal{P}(X)\to[0,+\infty]$ 是函数, 满足

1. (空集) $\mu^*(\emptyset)=0$.
2. (单调性) 若 $A\subseteq B\subseteq X$, 则 $\mu^*(A)\leq\mu^*(B)$.
3. (次可列可加性) 若 $A_n\subseteq X(n\in\mathbb{N}^*)$ 是一列子集, 则
$$\mu^*\left(\bigcup_{n=1}^{\infty}A_n\right)\leq\sum_{n=1}^{\infty}\mu^*(A_n).$$

则称 μ^* 是 X 上的外测度.

Proposition 6.(诱导外测度) 设 $\mathscr{F}\subseteq\mathcal{P}(X)$ 包含 $\emptyset$ 和 X, 集函数 $\mu:\mathscr{F}\to[0,+\infty]$, 使得 $\mu(\emptyset)=0$. 定义
$$\begin{aligned}\mu^*:\ \left\{A\subseteq X\mid A\subseteq\bigcup_{n=1}^{\infty}E_n,E_n\in\mathscr{F}\right\}&\to&&[0,+\infty],\\ A&\mapsto&&\inf\left\{\sum_{n=1}^{\infty}\mu(E_n)\mid A\subseteq\bigcup_{n=1}^{\infty}E_n,E_n\in\mathscr{F}\right\}.\end{aligned}$$
则这是一个外测度, 称为集函数 μ 诱导的外测度.

Proof. 注意到任意 $A\subseteq X$ 都被 X 覆盖, 故 μ^* 在 $\mathcal{P}(X)$ 上定义. 我们验证外测度的三条性质.

1. (空集) 取所有 $E_n=\emptyset$ 即知 $\mu(\emptyset)=0$.
2. (单调性) 设 $A\subseteq B\subseteq X$ 都能被可列个 E_n 覆盖, 则任意一个 B 的覆盖都能覆盖 A, 于是
$$B\subseteq\bigcup_{n=1}^{\infty}E_n\implies\mu^*(A)\leq\sum_{n=1}^{\infty}\mu(E_n).$$
取下确界即得 $\mu^*(A)\leq\mu^*(B)$.
3. (次可列可加性) 根据下确界的定义, 对任意 $\varepsilon>0$, 存在 A_n 的覆盖 $\{E_{n,m}\}$, 使得
$$\sum_{m=1}^{\infty}\mu(E_{n,m})<\mu^*(A_n)+\frac{\varepsilon}{2^n}.$$
对 n 求和, 可得
$$\sum_{n=1}^{\infty}\sum_{m=1}^{\infty}\mu(E_{n,m})\leq\sum_{n=1}^{\infty}\mu^*(A_n)+\varepsilon.$$
注意这里不要求右边收敛, 发散时总是取等, 而收敛时根据极限的性质即知取严格不等号. 注意到全部 $\{E_{n,m}\}$ 构成 A_n 并集的覆盖, 于是根据定义
$$\mu^*\left(\bigcup_{n=1}^{\infty}A_n\right)\leq\sum_{n=1}^{\infty}\sum_{m=1}^{\infty}\mu(E_{n,m})\leq\sum_{n=1}^{\infty}\mu^*(A_n)+\varepsilon.$$
根据 ε 的任意性, 可知
$$\mu^*\left(\bigcup_{n=1}^{\infty}A_n\right)\leq\sum_{n=1}^{\infty}\mu^*(A_n).$$

□

***Definition 11.(可测集)** 设 $\mu^*:\mathcal{P}(X)\to[0,+\infty]$ 是外测度, 定义集合 $A\subseteq X$ 是 μ^* 可测的当且仅当对任意 $E\subseteq X$, 有

$$\mu^*(E)=\mu^*(E\cap A)+\mu^*(E\cap(X\setminus A)).$$

****Theorem 7.(Caratheodory 定理)** 设 $\mu^*:\mathcal{P}(X)\to[0,+\infty]$ 是外测度, 则所有 μ^* 可测集构成 σ-代数 $\mathscr{F}$, 且 μ^* 在其上的限制是其上的测度.

Proof. 我们验证 $\mathscr{F}$ 满足 σ-代数的性质.

1. (全集) 显然有

$$\mu^*(E\cap X)+\mu^*(E\cap(X\setminus X))=\mu^*(E)+\mu^*(\emptyset)=\mu^*(E).$$

2. (补的封闭性) 设 $A\in\mathscr{F}$, 则对任意 $E\subseteq X$, 有

$$\mu^*(E)=\mu^*(E\cap A)+\mu^*(E\cap(X\setminus A)).$$

进而

$$\mu^*(E)=\mu^*(E\cap(X\setminus(X\setminus A)))+\mu^*(E\cap(X\setminus A))$$

表明 $X\setminus E\in\mathscr{F}$.

3. (并的封闭性) 先证明有限并. 设 $A,B\in\mathscr{F}$, 对任意 $E\subseteq X$, 有

$$\begin{aligned}
&\mu^*(E\cap(A\cup B))+\mu^*(E\cap(X\setminus(A\cup B)))\\
=&\mu^*(E\cap(A\cup B)\cap A)+\mu^*(E\cap(A\cup B)\cap(X\setminus A))+\mu^*(E\cap(X\setminus(A\cup B)))\\
=&\mu^*(E\cap A)+\mu^*(E\cap B\cap(X\setminus A))+\mu^*(E\cap(X\setminus A)\cap(X\setminus B))\\
=&\mu^*(E\cap A)+\mu^*(E\cap(X\setminus A))\\
=&\mu^*(E).
\end{aligned}$$

特别地, 当 $A\cap B=\emptyset$ 时, 有

$$\begin{aligned}
\mu^*(E\cap(A\cup B))&=\mu^*(E\cap(A\cup B)\cap A)+\mu^*(E\cap(A\cup B)\cap(X\setminus A))\\
&=\mu^*(E\cap A)+\mu^*(E\cap B).
\end{aligned}$$

再证明可列并. 设 $A_n\in\mathscr{F}(n\in\mathbb{N}^*)$ 是一列集合, 定义

$$B_1=A_1,\quad B_{n+1}=\left\{x\in A_{n+1}\mid x\notin\bigcup_{k=1}^{n}A_k\right\}=A_{n+1}\cap\left(X\setminus\bigcup_{k=1}^{n}A_k\right).$$

根据有限并的封闭性, $B_n \in \mathscr{F}$. 显然任意两个 B_i, B_j 无交, 且

$$\bigcup_{n=1}^{\infty} B_n = \bigcup_{n=1}^{\infty} A_n.$$

归纳可得对任意 $E \subseteq X$, 有

$$\mu^*\left(E \cap \left(\bigcup_{k=1}^{n} B_k\right)\right) = \sum_{k=1}^{n} \mu^*(E \cap B_k).$$

进而根据有限并的封闭性和外测度的单调性

$$\begin{aligned}
\mu^*(E) &= \mu^*\left(E \cap \left(\bigcup_{k=1}^{n} B_k\right)\right) + \mu^*\left(E \cap \left(X \setminus \bigcup_{k=1}^{n} B_k\right)\right) \\
&= \sum_{k=1}^{n} \mu^*(E \cap B_k) + \mu^*\left(E \cap \left(\bigcap_{k=1}^{n} X \setminus B_k\right)\right) \\
&\geq \sum_{k=1}^{n} \mu^*(E \cap B_k) + \mu^*\left(E \cap \left(\bigcap_{k=1}^{\infty} X \setminus B_k\right)\right)
\end{aligned}$$

取极限并由外测度的次可列可加性有

$$\begin{aligned}
\mu^*(E) &\geq \sum_{n=1}^{\infty} \mu^*(E \cap B_n) + \mu^*\left(E \cap \left(\bigcap_{n=1}^{\infty} X \setminus B_n\right)\right) \\
&\geq \mu^*\left(E \cap \left(\bigcup_{n=1}^{\infty} B_n\right)\right) + \mu^*\left(E \cap \left(\bigcap_{n=1}^{\infty} X \setminus B_n\right)\right) \\
&\geq \mu^*\left(E \cap \left(\left(\bigcup_{n=1}^{\infty} B_n\right) \cup \left(\bigcap_{n=1}^{\infty} X \setminus B_n\right)\right)\right) \\
&= \mu^*(E)
\end{aligned}$$

即得

$$\mu^*(E) = \mu^*\left(E \cap \left(\bigcup_{n=1}^{\infty} B_n\right)\right) + \mu^*\left(E \cap \left(\bigcap_{n=1}^{\infty} X \setminus B_n\right)\right),$$

这就说明了

$$\bigcup_{n=1}^{\infty} A_n = \bigcup_{n=1}^{\infty} B_n \in \mathscr{F}.$$

为证 μ^* 是 $\mathscr{F}$ 上的测度, 只要证明可列可加性. 若 $A_n \in \mathscr{F} (n \in \mathbb{N}^*)$ 是一列子集, 满足对任意 $i, j \in \mathbb{N}^*$ 使得 $i \neq j$, 都有 $A_i \cap A_j = \emptyset$, 则取

$$E = \bigcup_{n=1}^{\infty} A_n \subseteq X, \quad A = \bigcup_{k=1}^{n} A_k$$

有

$$\mu^*\left(\bigcup_{n=1}^{\infty} A_n\right) \geq \mu^*\left(\bigcup_{k=1}^{n} A_k\right) = \sum_{k=1}^{n} \mu^*(A_k).$$

取极限即得

$$\mu^*\left(\bigcup_{n=1}^{\infty} A_n\right) \geq \sum_{n=1}^{\infty} \mu^*(A_n).$$

结合次可列可加性即得可列可加性. □

**Theorem 8.(Caratheodory 测度扩张/延拓定理) 设 $\mathscr{F}$ 是 X 上的代数, $\mu : \mathscr{F} \to [0, +\infty)$ 是一个预测度, 则其诱导的外测度 $\mu^* : \mathcal{P}(X) \to [0, +\infty)$ 是 $\sigma(\mathscr{F})$ 上的测度, 且是唯一在 $\mathscr{F}$ 上限制为 μ 的测度.

Proof. 根据Theorem 7., 诱导的外测度自身的可测集是 σ-代数, 如果 $\mathscr{F}$ 的所有元素都是 μ^* 可测的, 则根据Definition 8., 这个 σ-代数必然包含 $\sigma(\mathscr{F})$, 从而是其上的测度. 我们证明 $\mathscr{F}$ 的所有元素都是 μ^* 可测的. 任取 $A \in \mathscr{F}$, 对任意的 $E \subseteq X$, 依照 μ^* 的定义, 对任意 $\varepsilon > 0$, 存在一列集合 $\{E_n\} \subseteq \mathscr{F}$ 覆盖 E, 使得

$$\sum_{n=1}^{\infty} \mu(E_n) \leq \mu^*(E) + \varepsilon.$$

根据 μ 作为预测度的可列可加性, 有

$$\sum_{n=1}^{\infty} \mu(E_n) = \sum_{n=1}^{\infty} \mu(E_n \cap A) + \sum_{n=1}^{\infty} \mu(E_n \cap (X \setminus A)).$$

根据 μ^* 的定义, 由于 $\{E_n\}$ 覆盖 E, $\{E_n \cap A\}$ 覆盖 $E \cap A$ 且 $\{E_n \cap (X \setminus A)\}$ 覆盖 $E \cap (X \setminus A)$, 于是

$$\sum_{n=1}^{\infty} \mu(E_n) \geq \mu^*(E \cap A) + \mu^*(E \cap (X \setminus A)).$$

另一方面, $E \cap A$ 和 E $(X \setminus A)$ 覆盖 E, 故有

$$\mu^*(E) + \varepsilon \geq \sum_{n=1}^{\infty} \mu(E_n) \geq \mu^*(E \cap A) + \mu^*(E \cap (X \setminus A)) \geq \mu^*(E).$$

由 ε 的任意性, 上式不等号全部取等, 从而

$$\mu^*(E) = \mu^*(E \cap A) + \mu^*(E \cap (X \setminus A)),$$

这就说明 A 是可测集.
再证明 μ^* 在 $\mathscr{F}$ 上的限制为 μ. 任取 $A \in \mathscr{F}$, 由于 A 覆盖自身, 有

$$\mu^*(A) \leq \mu(A).$$

现在任取一列集合 $\{E_n\} \subseteq \mathscr{F}$ 覆盖 A, 令

$$F_{n+1} = A \cap \left(E_{n+1} \setminus \bigcup_{k=1}^{n} E_k\right) \subseteq E_{n+1}.$$

由于这只涉及到补和有限并, 从而在代数 $\mathscr{F}$ 中, 于是根据 μ 作为预测度的可列可加性, 有

$$\mu(A) = \sum_{n=1}^{\infty} \mu(F_n) \leq \sum_{n=1}^{\infty} \mu(E_n).$$

对全体集合列 $\{E_n\}$ 取下确界, 即得

$$\mu(A) \leq \mu^*(A).$$

最后假设还有一个测度 $\nu : \sigma(\mathscr{F}) \to [0, +\infty)$, 使得其在 $\mathscr{F}$ 上的限制为 μ. 任取 $A \in \sigma(\mathscr{F})$, 对任意一个覆盖 A 的集合列 $\{E_n\} \subseteq \mathscr{F}$, 根据 ν 作为测度的单调性和可列可加性, 有

$$\nu(A) \leq \sum_{n=1}^{\infty} \nu(E_n) = \sum_{n=1}^{\infty} \mu(E_n).$$

对全体集合列 $\{E_n\}$ 取下确界, 即得

$$\nu(A) \leq \mu^*(A).$$

反之, 对任意 $\varepsilon > 0$, 存在一个覆盖 A 的集合列 $\{E_n\} \subseteq \mathscr{F}$, 满足

$$\sum_{n=1}^{n} \mu(E_n) \leq \mu^*(A) + \varepsilon.$$

定义

$$E_0 = \bigcup_{n=1}^{\infty} E_n, \quad G_n = \bigcup_{k=1}^{n} E_k,$$

由于这只涉及到补和有限并, 从而 $G_n \in \mathscr{F}$ 中. 根据 μ^* 在 $\mathscr{F}$ 上的限制为 μ 以及作为外测度的次可列可加性, 有

$$\sum_{n=1}^{n} \mu(E_n) = \sum_{n=1}^{n} \mu^*(E_n) \geq \mu^*(E_0).$$

由于 μ 值域有界, 故根据 μ^* 作为 $\sigma(\mathscr{F})$ 上测度的可列可加性, 有

$$\mu^*(E_0 \setminus A) = \mu^*(E_0) - \mu^*(A) \leq \varepsilon.$$

在前述证明中把 A 替换为 $E_0 \setminus A$ 即得 $\nu(E \setminus A) \leq \mu^*(E \setminus A)$, 于是

$$\nu(E_0) = \nu(A) + \nu(E \setminus A) \leq \nu(A) + \mu^*(E \setminus A) \leq \nu(A) + \varepsilon.$$

注意到

$$\nu^*(E_0) = \lim_{n\to\infty} \mu^*(G_n) = \lim_{n\to\infty} \nu(G_n) = \nu(E_0),$$

即得

$$\mu^*(A) \leq \mu^*(E_0) = \nu(E_0) \leq \nu(A) + \varepsilon.$$

根据 ε 的任意性即知

$$\mu^*(A) \leq \nu(A),$$

于是 $\nu = \mu^*$ 在 $\sigma(\mathscr{F})$ 上恒成立, 即 μ^* 是唯一的. □

1.3 概率论的公理化

Definition 12.(概率空间) 设 Ω 是集合, $\mathscr{F}$ 是 Ω 上的 σ-代数, P 是 $\mathscr{F}$ 上的测度, 满足 $P(\Omega)=1$, 则称 P 是 $\mathscr{F}$ 上的概率, $(\Omega,\mathscr{F},P)$ 是概率空间.

Remark. 给定可测空间 $(\Omega,\mathscr{F})$, 则集函数 $\mu:\mathscr{F}\to\mathbb{F}$ 是概率当且仅当满足

1. (非负性) 对任意 $A\in\mathscr{F}$, 有 $\mu(A)\geq 0$.
2. (归一性) $\mu(\emptyset)=0$, $\mu(\Omega)=1$.
3. (可列可加性) 若 $A_n\in\mathscr{F}(n\in\mathbb{N}^*)$ 是一列子集, 满足对任意 $i,j\in\mathbb{N}^*$ 使得 $i\neq j$, 都有 $A_i\cap A_j=\emptyset$, 则
$$\mu\left(\bigcup_{n=1}^{\infty}A_n\right)=\sum_{n=1}^{\infty}\mu(A_n).$$

Remark. 利用可列可加性容易得到

$$P(\Omega\setminus A)=P(\Omega)-P(A)=1-P(A).$$

Proposition 9.(加法公式) 设 $(\Omega,\mathscr{F},P)$ 是概率空间, $A_n\in\mathscr{F}$, 则有

$$P\left(\bigcup_{k=1}^{n}A_k\right)=\sum_{k=1}^{n}(-1)^{k-1}\left(\sum_{1\leq i_1<i_2<\cdots<i_k\leq n}P\left(\bigcap_{j=1}^{k}A_{i_j}\right)\right).$$

特别地, 对 $A,B\in\mathscr{F}$, 有

$$P(A\cup B)=P(A)+P(B)-P(A\cap B).$$

Proof. 对 n 归纳证明. 当 $n=2$ 时有

$$\begin{aligned}P(A\cup B)&=P((A\setminus A\cap B)\cup(B\setminus A\cap B)\cup(A\cap B))\\&=P(A\setminus A\cap B)+P(B\setminus A\cap B)+P(A\cap B)\\&=P((A\setminus A\cap B)\cup(A\cap B))+P((B\setminus A\cap B)\cup(A\cap B))-P(A\cap B)\\&=P(A)+P(B)-P(A\cap B).\end{aligned}$$

现在假设对 $n=m$ 成立, 则对 $n=m+1$, 可以把

$$\sum_{k=1}^{m+1}(-1)^{k-1}\left(\sum_{1\leq i_1<i_2<\cdots<i_k\leq m+1}P\left(\bigcap_{j=1}^{k}A_{i_j}\right)\right)$$

拆成两部分, 当 $k=1$ 时, 即

$$\sum_{1\leq i\leq m+1}P\left(A_i\right)=\sum_{i=1}^{m+1}P(A_i).$$

对 $2 \leq k \leq m+1$, 再拆成两项, 当 $i_k = m+1$ 时为

$$\sum_{k=2}^{m+1}(-1)^{k-1}\left(\sum_{1\leq i_1<i_2<\cdots<i_{k-1}\leq m} P\left(\bigcap_{j=1}^{k-1} A_{i_j}\cap A_{m+1}\right)\right).$$

以 k 代替 $k-1$, 运用归纳假设即得

$$-\sum_{k=1}^{m}(-1)^{k-1}\left(\sum_{1\leq i_1<i_2<\cdots<i_k\leq m} P\left(\bigcap_{j=1}^{k} A_{i_j}\cap A_{m+1}\right)\right) = -P\left(\bigcup_{k=1}^{m} A_k\cap A_{m+1}\right).$$

当 $i_k \leq m$ 时, k 不可能再取 $m+1$, 从而为

$$\sum_{k=2}^{m}(-1)^{k-1}\left(\sum_{1\leq i_1<i_2<\cdots<i_k\leq m} P\left(\bigcap_{j=1}^{k} A_{i_j}\right)\right).$$

补上 $k=1$ 的项即得

$$P\left(\bigcup_{k=1}^{m} A_k\right) - \sum_{i=1}^{m} P(A_i).$$

于是原式化为

$$P\left(\bigcup_{k=1}^{m} A_k\right) + P(A_{m+1}) - P\left(\bigcup_{k=1}^{m} A_k\cap A_{m+1}\right).$$

利用**Theorem 1.**和 $n=2$ 的情形即得

$$\sum_{k=1}^{m+1}(-1)^{k-1}\left(\sum_{1\leq i_1<i_2<\cdots<i_k\leq m+1} P\left(\bigcap_{j=1}^{k} A_{i_j}\right)\right) = P\left(\bigcup_{k=1}^{m+1} A_k\right).$$

归纳即证原命题. □

Definition 13.(条件概率) 设 $(\Omega, \mathscr{F}, P)$ 是概率空间, $A, B \in \mathscr{F}$, 使得 $P(B) > 0$, 称

$$\frac{P(A\cap B)}{P(B)}$$

为条件 B 下事件 A 的概率, 记作 $P(A \mid B)$.

Remark. 由定义立即得到

$$P(A\cap B) = P(A)P(B \mid A) = P(B)P(A \mid B).$$

Proposition 10.(全概率公式) 设 $(\Omega, \mathscr{F}, P)$ 是概率空间, $A, B_k \in \mathscr{F}(k = 1, 2, \ldots, n)$, 使得对任意 $i \neq j$ 都有 $B_i \cap B_j = \emptyset$, 对任意 $1 \leq k \leq n$ 都有 $P(B_k) > 0$, 以及

$$A \subseteq \bigcup_{k=1}^{n} B_k.$$

则有

$$P(A) = \sum_{k=1}^{n} P(B_k)P(A \mid B_k).$$

Proof. 包含关系两边交 A 即得

$$A = \bigcup_{k=1}^{n} B_k \cap A.$$

两边取概率, 由于 B_k 两两不交, 有

$$P(A) = \bigcup_{k=1}^{n} P(B_k \cap A).$$

根据**Definition 13.**即得

$$P(A) = \sum_{k=1}^{n} P(B_k)P(A \mid B_k).$$

□

Theorem 11.(Bayes) 设 $(\Omega, \mathscr{F}, P)$ 是概率空间, $A, B_k \in \mathscr{F}(k = 1, 2, \ldots, n)$, 使得对任意 $i \neq j$ 都有 $B_i \cap B_j = \emptyset$, 对任意 $1 \leq k \leq n$ 都有 $P(B_k) > 0$ 并且 $P(A) > 0$, 以及

$$A \subseteq \bigcup_{k=1}^{n} B_k.$$

则对任意 $1 \leq i \leq n$ 有

$$P(B_i \mid A) = \frac{P(B_i)P(A \mid B_i)}{\sum_{k=1}^{n} P(B_k)P(A \mid B_k)}.$$

Proof. 根据定义有

$$P(B_i \mid A) = \frac{P(A \cap B_i)}{P(A)} = \frac{P(B_i)P(A \mid B_i)}{P(A)}.$$

利用**Proposition 10.**的结果即得

$$P(B_i \mid A) = \frac{P(B_i)P(A \mid B_i)}{\sum_{k=1}^{n} P(B_k)P(A \mid B_k)}.$$

□

Definition 14.(独立性) 设 $(\Omega, \mathscr{F}, P)$ 是概率空间, $A_i \in \mathscr{F}(i = 1, 2, \ldots, n)$. 称这 n 个事件独立当且仅当对任意 $1 \leq i_1 < i_2 < \cdots < i_k \leq n$, 都有

$$P\left(\bigcap_{j=1}^{k} A_{i_j}\right) = \prod_{j=1}^{k} P(A_{i_j})$$

都成立.

Remark. 特别地, 两个时间 $A, B \in \mathscr{F}$ 独立当且仅当

$$P(A \cap B) = P(A)P(B) \iff P(A) = P(A \mid B) \iff P(B) = P(B \mid A).$$

注意 n 个事件独立能推出 n 个事件两两独立, 反之不然.

Theorem 12.(Borel-Cantelli) 设 $(\Omega, \mathscr{F}, P)$ 是概率空间, $A_n \in \mathscr{F}$ 是一列集合. 若级数 $\sum\limits_{n=1}^{\infty} P(A_n)$ 收敛, 则

$$P\left(\limsup_{n\to\infty} A_n\right) = 0.$$

若级数 $\sum\limits_{n=1}^{\infty} P(A_n)$ 发散, 且无穷多个 A_n 独立, 则

$$P\left(\limsup_{n\to\infty} A_n\right) = 1.$$

Proof. 对收敛的情形, 根据**Proposition 3.**可知连续, 再由可列可加性

$$P\left(\limsup_{n\to\infty} A_n\right) = \lim_{m\to\infty} P\left(\bigcup_{n=m}^{\infty} A_n\right) \leq \lim_{m\to\infty} \sum_{n=m}^{\infty} A_n.$$

注意到收敛性

$$\lim_{m\to\infty} \sum_{n=m}^{\infty} A_n = \sum_{n=1}^{\infty} A_n - \lim_{m\to\infty} \sum_{n=1}^{m-1} A_n = 0.$$

这就证明了收敛的情形. 对发散的情形, 根据**Theorem 1.**和独立性有

$$1 - P\left(\bigcup_{n=m}^{\infty} A_n\right) = P\left(\bigcap_{n=m}^{\infty} \Omega \setminus A_n\right) = \prod_{n=m}^{\infty} P(\Omega \setminus A_n) = \prod_{n=m}^{\infty} (1 - P(A_n)).$$

作放缩

$$\prod_{n=m}^{\infty} (1 - P(A_n)) \leq \prod_{n=m}^{\infty} \exp(-P(A_n)) = \exp\left(-\sum_{n=m}^{\infty} P(A_n)\right) = 0.$$

于是

$$P\left(\limsup_{n\to\infty} A_n\right) = \lim_{m\to\infty} P\left(\bigcup_{n=m}^{\infty} A_n\right) = 1.$$

□

Remark. 这说明若事件列相互独立, 则其上极限的概率

$$P\left(\limsup_{n\to\infty} A_n\right) = P\left(\lim_{m\to\infty} \bigcup_{n=m}^{\infty} A_n\right) = P\left(\bigcap_{m=1}^{\infty} \bigcup_{n=m}^{\infty} A_n\right)$$

只可能取 0 和 1 而没有中间值.

Definition 15.(Borel 集) 设 $(X, \mathscr{F})$ 是拓扑空间, 定义 Borel 集 $\mathscr{B} = \sigma(\mathscr{F})$. 特别地, $\mathbb{R}$ 对其上所有开集构成拓扑空间, 其上的 Borel 集记作 $\mathscr{B}_{\mathbb{R}}$.

Remark. Borel 集是包含 $\mathscr{F}$ 的最小的 X 上的 σ-代数. 拓扑空间 $(X, \mathscr{F})$ 上定义适当的 Lebesgue 测度 P, $(X, \mathscr{B}, P)$ 构成概率空间, $(\mathbb{R}, \mathscr{B}_{\mathbb{R}}, P)$ 是最常用的概率空间之一.

Chapter 2

一元概率论

2.1 随机变量与分布

Definition 16.(随机变量) 设 $(\Omega, \mathscr{F}, P)$ 是概率空间. 若函数 $X : \Omega \to \mathbb{R}$ 满足对任意 $B \in \mathscr{B}_{\mathbb{R}}$, 都有

$$\{\omega \in \Omega \mid X(\omega) \in B\} \in \mathscr{F},$$

称 X 是一个随机变量.

Definition 17.(分布函数) 设 $(\Omega, \mathscr{F}, P)$ 是概率空间, X 是其上的一个随机变量. 定义

$$F(x) = P(X \leq x) = P(\{\omega \in \Omega \mid X(\omega) \leq x\})$$

为 X 的概率分布函数.

Proposition 13. 设 $(\Omega, \mathscr{F}, P)$ 是概率空间, X 是其上的一个随机变量, 则 X 的概率分布函数 $F(x)$ 满足

1. (单调性) 任意 $x < y$ 都有 $F(x) \leq F(y)$.
2. (连续性) $F(x)$ 在任一点处右连续, 即

$$\lim_{x \to x_0^+} F(x) = F(x_0),$$

且左极限

$$\lim_{x \to x_0^-} F(x) = P(X < x) = P(\{\omega \in \Omega \mid X(\omega) < x\}).$$

3. 在无穷远处

$$\lim_{x \to -\infty} F(x) = 0, \quad \lim_{x \to +\infty} F(x) = 1.$$

Proof.

1. 注意到
$$x < y \implies \{\omega \in \Omega \mid X(\omega) \le x\} \subseteq \{\omega \in \Omega \mid X(\omega) \le y\},$$
即知 $F(x) \le F(y)$.

2. 任取一列 $\{x_n\}$ 单调下降趋于 x_0, 则根据 Heine-Borel 定理有
$$\lim_{x \to x_0^+} F(x) = \lim_{n \to \infty} F(x_n) = \lim_{n \to \infty} P(X \le x_n) = P\left(\bigcap_{n=1}^{\infty} \{\omega \in \Omega \mid X(\omega) \le x_n\}\right).$$
利用极限的性质显然有
$$\bigcap_{n=1}^{\infty} \{\omega \in \Omega \mid X(\omega) \le x_n\} = \{\omega \in \Omega \mid X(\omega) \le x_0\},$$
即得
$$\lim_{x \to x_0^+} F(x) = F(x_0).$$
类似地, 根据 $F(x)$ 在 $(-\infty, x_0)$ 上单调有界, 可知左极限存在. 任取 $\{x_n\}$ 单调上升趋于 x_0, 有
$$\lim_{x \to x_0^-} F(x) = P\left(\bigcup_{n=1}^{\infty} \{\omega \in \Omega \mid X(\omega) \le x_n\}\right) = P(\{\omega \in \Omega \mid X(\omega) < x\}).$$

3. 任取 $\{x_n\}$ 单调下降趋于 $-\infty$, 有
$$\lim_{x \to -\infty} F(x) = P\left(\bigcap_{n=1}^{\infty} \{\omega \in \Omega \mid X(\omega) \le x_n\}\right) = P(\emptyset) = 0.$$
任取 $\{x_n\}$ 单调上升趋于 $+\infty$, 有
$$\lim_{x \to +\infty} F(x) = P\left(\bigcup_{n=1}^{\infty} \{\omega \in \Omega \mid X(\omega) \le x_n\}\right) = P(\Omega) = 1.$$

□

****Theorem 14.(Lebesgue-Stieljes, 概率空间的存在性)** 设 $F : \mathbb{R} \to \mathbb{R}$ 单调上升, 在任意一点处右连续且左极限存在, 满足
$$\lim_{x \to -\infty} F(x) = 0, \quad \lim_{x \to +\infty} F(x) = 1.$$
则存在概率空间 $(\Omega, \mathscr{F}, P)$ 以及其上的随机变量 X, 使得 $F(x)$ 是 X 的概率分布函数.

Proof. 取样本空间 $\Omega=\mathbb{R}$, 事件域 $\mathscr{F}=\mathscr{B}_{\mathbb{R}}$, 我们定义区间 $(a,b]$ 上的概率为

$$P((a,b])=F(b)-F(a).$$

注意到

$$\{(a,b]\mid a,b\in\mathbb{R},a\leq b\}\subseteq\mathcal{P}(\mathbb{R})$$

对有限交封闭, 只要定义 $(a,b]$ 补集的概率

$$\tilde{P}\left(\mathbb{R}\setminus(a,b]\right)=1-(F(b)-F(a)),$$

就在一个代数 $\mathscr{A}$ 上定义了概率 $\tilde{P}$. 我们证明这个代数生成的 σ-代数恰好为 $\mathscr{B}_{\mathbb{R}}$. 一方面, 任意开集 (a,b) 可由

$$(a,b)=\bigcup_{n=1}^{\infty}\left(a,b-\frac{1}{n}\right]$$

确定, 从而 $\mathscr{B}_{\mathbb{R}}\subseteq\sigma(\mathscr{A})$. 另一方面, 任意 $(a,b]$ 可由

$$(a,b]=\bigcap_{n=1}^{\infty}\left(a,b+\frac{1}{n}\right)$$

确定, 于是 $\mathscr{B}_{\mathbb{R}}=\sigma(\mathscr{A})$. 从而根据**Theorem 8.**可知此概率可以延拓为 $P:\mathscr{B}_{\mathbb{R}}\to\mathbb{R}$. 令随机变量 $X=\mathrm{id}_{\mathbb{R}}$ 即可. □

****Theorem 15.(Skorokhod)** 设 $F:\mathbb{R}\to\mathbb{R}$ 单调上升, 在任意一点处右连续且左极限存在, 满足

$$\lim_{x\to-\infty}F(x)=0,\quad\lim_{x\to+\infty}F(x)=1.$$

则存在概率空间 $([0,1],\mathscr{B}([0,1]),P)$ 以及其上的随机变量 X, 使得 $F(x)$ 是 X 的概率分布函数.

Proof. 定义概率

$$\begin{aligned}P:\ \{[a,b]\mid 0\leq a\leq b\leq 1\}&\to[0,1],\\ [a,b]&\mapsto F(b)-F(a).\end{aligned}$$

同**Theorem 13.** 延拓到 $\mathscr{B}([0,1])$. 定义随机变量

$$\begin{aligned}X:\ [0,1]&\to\mathbb{R},\\ \omega&\mapsto\inf\{x\in\mathbb{R}\mid F(x)\geq\omega\}.\end{aligned}$$

则当 $\omega\leq F(x)$ 时, $X(\omega)\leq x$, 而 $\omega>F(x)$ 时, 根据 $F(x)$ 单调上升, 任意 $y\leq x$ 都有 $\omega>F(y)$, 从而 $X(\omega)\geq x$, 这就说明分布函数

$$\tilde{F}(x)=P(X\leq x)=P(\omega\leq F(x))=F(x)-F(0)=F(x).$$

□

Remark. 这说明, 不必指定概率空间, 仅仅指定 $F(x)$ 就可以讨论概率, 因此我们可以直接称满足以上条件的 F 为分布函数.

***Definition 18.(离散, 绝对连续与奇异)** 设 $F:\mathbb{R}\to\mathbb{R}$. 若存在严格单调上升序列 $\{x_n\}\subseteq\mathbb{R}$ 和 $p_n\in[0,1]$, 使得

$$F(x)=\sum_{x_n\le x}p_n,$$

则称 $F(x)$ 离散. 若存在 Lebesgue 可积函数 $f(x)$, 使得对任意 $x_1<x_2$, 有

$$F(x_2)-F(x_1)=\int_{x_1}^{x_2}f(x)\mathrm{d}x,$$

则称 $F(x)$ 绝对连续. 若 $F(x)$ 几乎处处可导且导数恒为 0, 但 $F(x)$ 不恒为 0, 则称 $F(x)$ 奇异.

****Theorem 16.(Lebesgue)** 设 $F:\mathbb{R}\to\mathbb{R}$ 是分布函数, 则存在分布函数 F_1,F_2,F_3 分别是离散的, 绝对连续的和奇异的, 以及 $\lambda_1,\lambda_2,\lambda_3\in[0,1]$, 使得

$$F(x)=\lambda_1F_1(x)+\lambda_2F_2(x)+\lambda_3F_3(x),$$

且这样的分解唯一.

Proof. 由于 $F(x)$ 单调上升, 至多只有可数个间断点, 且按定义左极限存在而右连续, 设为 $x_n(n\in\mathbb{Z})$. 定义

$$F_d(x)=\sum_{n\in\mathbb{Z}}\left(F(x_n)-\lim_{t\to x_n^-}F(t)\right)\delta_{x_n}(x),$$

其中

$$\delta_u(x)=\begin{cases}0, & x<u,\\ 1, & x\ge u.\end{cases}$$

$F_d(x)$ 定义合理, 因为任意一点处

$$F_d(x)\le\sum_{n\in\mathbb{Z}}\left(F(x_n)-\lim_{t\to x_n^-}F(t)\right)\le\lim_{t\to+\infty}F(t)-\lim_{t\to-\infty}F(t)=1.$$

显然 $F_d(x)$ 的间断点恰好是 $F(x)$ 的间断点, 且 $F_d(x)$ 右连续, 左极限存在, 单调上升. 于是 $F(x)-F_d(x)$ 在 $\{x_n\}$ 以外处处连续. 再考虑

$$\begin{aligned}&\lim_{x\to x_n^-}F_d(x)-F_d(x_n)\\ =&\sum_{m<n}\left(F(x_m)-\lim_{t\to x_m^-}F(t)\right)\delta_{x_m}(x)-\sum_{m\le n}\left(F(x_m)-\lim_{t\to x_m^-}F(t)\right)\delta_{x_m}(x)\\ =&\lim_{x\to x_n^-}F(x)-F(x_n).\end{aligned}$$

从而

$$\lim_{x\to x_n^-}(F(x)-F_d(x))=(F(x_n)-F_d(x_n)),$$

这就说明 $G(x):=F(x)-F_d(x)$ 是连续函数. 对任意 $t_1<t_2$, 若中间不存在 $t_1\le x_n\le t_2$, 则 $F_d(t_1)=F_d(t_2)$, 进而

$$G(t_1)-G(t_2)=F(t_1)-F(t_2)\le 0 \implies G(t_1)\le G(t_2).$$

否则可在 $t_1<t_2$ 间插入所有的 x_n, $G(x)$ 在每个 (x_{n-1},x_n) 上单调而在端点处连续, 从而 $G(x)$ 单调上升. 又由于单调函数的不可导点是 Lebesgue 零测的, 从而 $G'(x)$ 是 Lebesgue 可积的, 进而可定义

$$F_{ac}(x)=\int_{-\infty}^{x}G'(t)\mathrm{d}t.$$

由于 $G(x)$ 单调上升, $G'(t)\ge 0$, 从而 $F_{ac}(x)$ 单调上升且连续. 再定义

$$F_s(x)=G(x)-F_{ac}(x),$$

则

$$F_s'(x)=F'(x)-F_{ac}'(x)=0$$

在所有可导点成立, 从而 $F_s(x)$ 几乎处处可导且导数恒为 0. 依照定义 $F_s(x)$ 右连续且左极限存在. 对任意 $t_1<t_2$, 有

$$F_s(t_2)-F_s(t_1)=G(t_2)-G(t_1)+\int_{t_1}^{t_2}G'(t)\mathrm{d}t\ge 0.$$

显然 F_d,F_{ac},F_s 均满足在 $-\infty$ 处极限为 0, 以及单调上升, 右连续, 左极限存在. 注意到这表明 F_d,F_{ac},F_s 均恒正, 于是

$$F(x)=F_d(x)+F_{ac}(x)+F_s(x)\le 1$$

表明 F_d,F_{ac},F_s 单调有界, 从而在 $+\infty$ 处收敛到 $[0,1]$ 中的某个值, 设为 $\lambda_1,\lambda_2,\lambda_3$, 则有 Lebesgue 分解

$$F(x)=\lambda_1\left(\frac{1}{\lambda_1}F_d(x)\right)+\lambda_2\left(\frac{1}{\lambda_2}F_d(x)\right)+\lambda_3\left(\frac{1}{\lambda_3}F_d(x)\right).$$

这三项依次就是离散分布函数, 绝对连续分布函数和奇异分布函数. 若 $\lambda_i=0$, 只要把分解项取为 0 即可. 取 $x\to\infty$ 即知 $\lambda_1+\lambda_2+\lambda_3=1$. 现在假设存在分解

$$F(x)=\lambda_1F_1(x)+\lambda_2F_2(x)+\lambda_3F_3(x)=\lambda_1^*F_1^*(x)+\lambda_2^*F_2^*(x)+\lambda_3^*F_3^*(x),$$

则有

$$\lambda_1F_1(x)-\lambda_1^*F_1^*(x)=\lambda_2^*F_2^*(x)+\lambda_3^*F_3^*(x)-\lambda_2F_2(x)-\lambda_3F_3(x),$$

但左边离散右边连续, 从而必须均为 0. 又有

$$\lambda_2^* F_2^*(x) - \lambda_2 F_2(x) = \lambda_3 F_3(x) - \lambda_3^* F_3^*(x),$$

则左边连续且处处可导, 而右边表明导数几乎处处为 0, 从而只能是常数, 且恰为

$$\lim_{x\to-\infty} (\lambda_2^* F_2^*(x) - \lambda_2 F_2(x)) = 0.$$

这就说明了 $\lambda_i F_i(x) = \lambda_i^* F_i^*(x)$, 进而

$$\lim_{x\to+\infty} \lambda_i F_i(x) = \lim_{x\to+\infty} \lambda_i^* F_i^*(x) \implies \lambda_i = \lambda_i^*,$$

这就证明了唯一性. □

Remark. 我们将对应于离散, 绝对连续, 奇异分布函数的随机变量 X 分别称为离散, 连续, 奇异型随机变量. Lebesgue 分解定理表明, 只要分别研究这三种随机变量和分布函数即可.

Definition 19.(概率密度函数) 设 $(\Omega, \mathscr{F}, P)$ 是概率空间, X 是其上的一个随机变量, $F(x)$ 为 X 的概率分布函数. 若存在 $f : \mathbb{R} \to [0, +\infty)$Lebesgue 可积, 且

$$\int_{-\infty}^{x} f(t)\mathrm{d}t = F(x),$$

则称 $f(x)$ 是随机变量 X 的概率密度函数.

Corollary 17. 设 $(\Omega, \mathscr{F}, P)$ 是概率空间, 若其上的随机变量 X 存在概率密度函数, 则

$$\int_{-\infty}^{+\infty} f(t)\mathrm{d}t = \lim_{x\to\infty} F(x) = 1.$$

根据变上限积分的性质, 若 $f(x)$ 在 x_0 处连续, 则 $F(x)$ 在 x_0 处可导, 且 $F'(x_0) = f(x_0)$, 同时

$$P(X = x_0) = F(x_0) - \lim_{x\to x_0^-} F(x) = 0.$$

Corollary 18. 绝对连续分布函数 $F_{ac}(x)$ 必定存在概率密度函数, 且

$$f_{ac}(x) = F'_{ac}(x).$$

Example 2.(二项分布) 取样本空间 Ω 为独立重复做成功概率为 p 的随机试验 n 次的结果, 令随机变量 X 表示成功次数, 则

$$P(X = k) = C_n^k p^k (1-p)^{n-k}.$$

称 X 服从二项分布, 记作 $X \sim B(n, p)$.

Example 3.(几何分布) 取样本空间 Ω 为独立重复做成功概率为 p 的随机试验直到成功的结果, 令随机变量 X 表示成功时进行的总次数, 则

$$P(X=k)=p(1-p)^{k-1}.$$

称 X 服从几何分布.

Example 4.(超几何分布) 取样本空间 Ω 为从有 $N-M$ 个次品的 N 个产品中不放回地取 n 个的结果, 令随机变量 X 表示非次品的个数, 则

$$P(X=m)=\frac{C_M^m C_{N-M}^{n-m}}{C_N^n}.$$

称 X 服从超几何分布.

Example 5.(均匀分布) 取样本空间 $\Omega=\mathbb{R}$, 概率密度函数

$$f(x)=\begin{cases}\frac{1}{b-a}, & a<x<b,\\ 0, & \text{otherwise.}\end{cases}$$

依次定义 $F(x), P, X$, 称此随机变量服从均匀分布 $X\sim U(a,b)$.

Example 6.(指数分布) 取样本空间 $\Omega=\mathbb{R}$, 概率密度函数

$$f(x)=\begin{cases}\lambda \mathrm{e}^{-\lambda x}, & x\geq 0,\\ 0, & x<0.\end{cases}$$

依次定义 $F(x), P, X$, 称此随机变量服从指数分布 $X\sim \mathscr{E}(\lambda)$.

Example 7.(Gamma 分布) 取样本空间 $\Omega=\mathbb{R}$, 概率密度函数

$$f(x)=\begin{cases}\mathrm{e}^{-\lambda x}\lambda^{\alpha}\frac{x^{\alpha-1}}{\Gamma(\alpha)}, & x>0,\\ 0, & x\leq 0.\end{cases}$$

依次定义 $F(x), P, X$, 称此随机变量服从 Gamma 分布 $X\sim \Gamma(\alpha,\lambda)$.

Example 8.(Cauchy 分布) 取样本空间 $\Omega=\mathbb{R}$, 概率密度函数

$$f(x)=\frac{1}{\pi(1+x^2)}.$$

依次定义 $F(x), P, X$, 称此随机变量服从 Cauchy 分布.

Definition 20.(正态分布) 取样本空间 $\Omega = \mathbb{R}$, 概率密度函数

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right).$$

依照积分定义 $F(x)$, 依照**Theorem 8.**定义 P, 称此概率空间中的随机变量 $X = \mathrm{id}_{\mathbb{R}}$ 服从正态分布 $X \sim N(\mu, \sigma^2)$.

Proposition 19. 设 $(\Omega, \mathscr{F}, P)$ 是概率空间, X 是连续型随机变量, $\varphi : \mathbb{R} \to \mathbb{R}$ 严格单调, 则随机变量

$$\begin{array}{rccc} Y: & \Omega & \to & \mathbb{R}, \\ & \omega & \mapsto & \varphi(X(\omega)) \end{array}$$

的概率密度函数满足

$$f_Y(y) = \frac{f_X(\varphi^{-1}(y))}{|\varphi'(y)|}.$$

Proof. 不妨设 φ 严格单调上升, 则

$$F_Y(y) = P(Y \le y) = P(\varphi(X) \le y) = P(X \le \varphi^{-1}(y)) = \int_{-\infty}^{\varphi^{-1}(y)} f_X(x)\mathrm{d}x.$$

两边对 y 求导得

$$f_Y(y) = f_X(\varphi^{-1}(y))\frac{\mathrm{d}}{\mathrm{d}y}\varphi^{-1}(y) = \frac{f_X(\varphi^{-1}(y))}{|\varphi'(y)|}.$$

同理可证严格单调下降的情形. □

2.2 期望与方差

Definition 21.(数学期望) 设 $(\Omega, \mathscr{F}, P)$ 是概率空间, X 是其上的随机变量, 分布函数为 $F(x)$, 满足

$$\int_{-\infty}^{+\infty} |x| \mathrm{d}F(x)$$

收敛. 则称

$$E(X) = \int_{-\infty}^{+\infty} x \mathrm{d}F(x)$$

为随机变量 X 的数学期望.

Remark. 定义中绝对收敛的条件决定了数学期望表达式的结果存在且与积分 (求和) 次序无关, 从而可以计算出唯一的结果. 事实上, 更一般地, 我们定义期望

$$E(X) = \int_{\Omega} X(\omega) \mathrm{d}P(\omega),$$

则容易得到线性

$$E(X+Y) = \int_{\Omega} (X(\omega)+Y(\omega)) \mathrm{d}P(\omega) = \int_{\Omega} X(\omega) \mathrm{d}P(\omega) + \int_{\Omega} Y(\omega) \mathrm{d}P(\omega) = E(X)+E(Y).$$

我们将在多元概率论中再次说明这一点.

Example 9. 考虑 Cauchy 分布

$$f(x) = \frac{1}{\pi(1+x^2)}.$$

有

$$\int_{-\infty}^{+\infty} |x| \mathrm{d}F(x) = \int_{-\infty}^{+\infty} |x| f(x) \mathrm{d}x = \int_{-\infty}^{+\infty} \frac{|x|}{\pi(1+x^2)} \mathrm{d}x = \int_{0}^{+\infty} \frac{2x}{\pi(1+x^2)} \mathrm{d}x,$$

这一积分的结果是

$$\lim_{x \to +\infty} \frac{1}{\pi} \ln(1+x^2) = +\infty,$$

于是数学期望不存在.

Proposition 20. 设 $(\Omega, \mathscr{F}, P)$ 是概率空间, $X : \Omega \to \mathbb{R}^+$ 是随机变量, 使得数学期望 $E(X)$ 存在, 则

$$E(X) = \int_{0}^{+\infty} P(X > x) \mathrm{d}x.$$

Proof. 利用分部积分法

$$\begin{aligned} \int_{0}^{+\infty} P(X > x) \mathrm{d}x &= \int_{0}^{+\infty} (1 - F(x)) \mathrm{d}x \\ &= \lim_{x \to +\infty} x(1 - F(x)) - \int_{0}^{+\infty} x \mathrm{d}(1 - F(x)) \\ &= \lim_{x \to +\infty} x(1 - F(x)) + \int_{0}^{+\infty} x \mathrm{d}F(x). \end{aligned}$$

注意到 X 是非负的随机变量, 根据数学期望存在的要求

$$\int_0^{+\infty} x\mathrm{d}F(x)$$

收敛, 可得

$$0 = \lim_{x\to+\infty}\int_x^{+\infty} t\mathrm{d}F(t) \geq \lim_{x\to+\infty} x\int_x^{+\infty}\mathrm{d}F(t) = \lim_{x\to+\infty} x(1-F(x)) \geq 0,$$

于是

$$\int_0^{+\infty} P(X>x)\mathrm{d}x = \int_0^{+\infty} x\mathrm{d}F(x) = E(X).$$

□

Remark. 当 X 是离散型随机变量时, 设随机变量的取值为

$$0 = x_0 < x_1 < x_2 < \cdots < x_n < \cdots$$

则上式为

$$E(X) = \sum_{k=1}^{\infty}(x_k - x_{k-1})P(X > x_k).$$

当 X 恰好取正整数值时, 上式可进一步写为

$$E(X) = \sum_{k=1}^{\infty} P(X>k).$$

Proposition 21. 设 $(\Omega, \mathscr{F}, P)$ 是概率空间, X 是其上的随机变量, $F(x)$ 为其分布函数. $\varphi:\mathbb{R}\to\mathbb{R}$ 是可测函数, 随机变量

$$\begin{array}{rccc} Y: & \Omega & \to & \mathbb{R}, \\ & \omega & \mapsto & \varphi(X(\omega)) \end{array}$$

的数学期望存在, 则

$$E(Y) = \int_{-\infty}^{+\infty}\varphi(x)\mathrm{d}F(x).$$

Proof. 我们分三步完成证明. 先对 φ 是离散型函数, 即存在可列个点 $x_i\in\mathbb{R}$ 和 $\lambda_i\in\mathbb{R}^+$, 使得

$$\varphi(x) = \sum_{i\in\mathbb{Z}}\lambda_i I_{[x_i,x_{i+1})}(x),$$

其中

$$I_D(x) = \begin{cases} 1, & x\in D, \\ 0, & x\in\mathbb{R}\setminus D. \end{cases}$$

则根据定义

$$E(Y) = \sum_{i\in\mathbb{Z}}\varphi(x_i)P(x_i\leq X<x_{i+1}) = \int_{-\infty}^{+\infty}\varphi(x)\mathrm{d}F(x).$$

再对 φ 是非负可测函数, 定义

$$\varphi_n(x)=\sum_{k=0}^{n2^n-1}\frac{k}{2^n}I_{\left\{x\in\mathbb{R}|\frac{k}{2^n}\le f(x)<\frac{k+1}{2^n}\right\}}(x)+nI_{\{x\in\mathbb{R}|f(x)\ge n\}}(x).$$

则这是一列离散型函数, 且在每一点处单调上升, 极限为 $\varphi(x)$. 记 $Y_n=\varphi_n(X)$, 则

$$E(Y_n)=\int_{-\infty}^{+\infty}\varphi_n(x)\mathrm{d}F(x).$$

由于 φ_n 非负, 根据 Fatou 引理, 有

$$\lim_{n\to\infty}E(Y_n)\ge\int_{-\infty}^{+\infty}\lim_{n\to\infty}\varphi_n(x)\mathrm{d}F(x)=\int_{-\infty}^{+\infty}\varphi(x)\mathrm{d}F(x).$$

但由于 φ_n 单调上升, 有

$$E(Y_n)\le\int_{-\infty}^{+\infty}\varphi(x)\mathrm{d}F(x).$$

取极限则有

$$E(Y)=\lim_{n\to\infty}E(Y_n)=\int_{-\infty}^{+\infty}\varphi(x)\mathrm{d}F(x).$$

最后对 φ 是一般的可测函数, 定义

$$\varphi^+(x)=\max\{\varphi(x),0\},\quad \varphi^-(x)=\min\{\varphi(x),0\},$$

则

$$\varphi(x)=\varphi^+(x)-(-\varphi^-(x)).$$

由于 Y 的数学期望存在, 可以改变求和次序

$$E(Y)=\int_{-\infty}^{+\infty}\varphi^+(x)\mathrm{d}F(x)-\int_{-\infty}^{+\infty}(-\varphi^-(x))\mathrm{d}F(x)=\int_{-\infty}^{+\infty}\varphi(x)\mathrm{d}F(x).$$

□

Corollary 22. 设 $(\Omega,\mathscr{F},P)$ 是概率空间, $X:\Omega\to\mathbb{R}^+$ 是随机变量, $\alpha\in\mathbb{N}^*$, 使得数学期望 $E(X)$ 和 $E(X^\alpha)$ 存在, 则

$$E(X^\alpha)=\alpha\int_0^{+\infty}x^{\alpha-1}P(X>x)\mathrm{d}x.$$

Proof. 利用**Proposition 21.**的结果

$$\begin{aligned}E(X^\alpha)&=\int_0^{+\infty}x^\alpha\mathrm{d}F(x)\\&=-\int_0^{+\infty}x^\alpha\mathrm{d}(1-F(x))\\&=-\lim_{x\to+\infty}x^\alpha(1-F(x))+\int_0^{+\infty}(1-F(X))\mathrm{d}x^\alpha\\&=\alpha\int_0^{+\infty}x^{\alpha-1}P(X>x)\mathrm{d}x.\end{aligned}$$

□

Definition 22.(方差) 设 $(\Omega, \mathscr{F}, P)$ 是概率空间, X 是其上的随机变量, 使得 X 和 X^2 的数学期望存在 (收敛), 则称

$$D(X) = E((X - E(X))^2)$$

为随机变量 X 的方差, 也称 $\sqrt{D(X)}$ 为随机变量 X 的标准差.

Corollary 23. 设 $(\Omega, \mathscr{F}, P)$ 是概率空间, X 是其上的随机变量, 使得 X 和 X^2 的数学期望存在 (收敛), 则

$$D(X) = E\left(X^2\right) - E(X)^2.$$

特别地, 若 X 非负, 则

$$D(X) = 2\int_0^{+\infty} xP(X > x) - E(X)^2.$$

Proof. 利用**Proposition 21.**的结果, 有

$$\begin{aligned} D(X) &= \int_{-\infty}^{+\infty} ((x - E(X))^2) \mathrm{d}F(x) \\ &= \int_{-\infty}^{+\infty} x^2 \mathrm{d}F(x) - 2E(X)\int_{-\infty}^{+\infty} x\mathrm{d}F(x) + E(X)^2 \int_{-\infty}^{+\infty} \mathrm{d}F(x) \\ &= E\left(X^2\right) - 2E(X)^2 + E(X)^2 \\ &= E\left(X^2\right) - E(X)^2. \end{aligned}$$

若 X 非负, 结合**Corollary 22.**的结果, 取 $\alpha = 2$ 即得

$$D(X) = 2\int_0^{+\infty} xP(X > x) - E(X)^2.$$

□

Remark. 这解释了方差定义中要求 $E(X)^2$ 存在的原因. 一般而言, 我们称 $E(X^\alpha)$ 为 X 的 α 阶矩 (moments).

Proposition 24. 设 $(\Omega, \mathscr{F}, P)$ 是概率空间, X 是其上的随机变量, 使得 X 和 X^2 的数学期望存在 (收敛), 则对 $a, b \in \mathbb{R}$, 有

$$D(aX + b) = a^2 D(X).$$

Proof. 利用**Proposition 21.**的结果计算

$$\begin{aligned} E((aX + b)^2) &= \int_{-\infty}^{+\infty} ((ax + b)^2) \mathrm{d}F(x) \\ &= a^2 \int_{-\infty}^{+\infty} x^2 \mathrm{d}F(x) + 2ab\int_{-\infty}^{+\infty} x\mathrm{d}F(x) + b^2 \int_{-\infty}^{+\infty} \mathrm{d}F(x) \\ &= a^2 E\left(X^2\right) + 2abE(X) + b^2. \end{aligned}$$

同样

$$E(aX+b)=aE(X)+b,$$

于是

$$\begin{aligned}D(aX+b)&=a^2E\left(X^2\right)+2abE(X)+b^2-(aE(X)+b)^2\\&=a^2E\left(X^2\right)-a^2E(X)^2\\&=a^2D(X).\end{aligned}$$

□

Example 10.(二项分布的期望和方差) 设 $(\Omega,\mathscr{F},P)$ 是概率空间, X 是其上的随机变量, 服从二项分布 $X\sim B(n,p)$, 则期望

$$E(X)=\sum_{k=0}^{n}kC_n^kp^k(1-p)^{n-k}=np.$$

$$E\left(X^2\right)=\sum_{k=0}^{n}k^2C_n^kp^k(1-p)^{n-k}=n(n-1)p^2+np.$$

方差

$$D(X)=n(n-1)p^2+np-(np)^2=np(1-p).$$

Example 11.(几何分布的期望和方差) 设 $(\Omega,\mathscr{F},P)$ 是概率空间, X 是其上的随机变量, 服从几何分布

$$P(X=k)=p(1-p)^{k-1}.$$

则期望

$$E(X)=\sum_{k=1}^{\infty}kp(1-p)^{k-1}=\frac{1}{p}.$$

$$E\left(X^2\right)=\sum_{k=1}^{\infty}k^2p(1-p)^{k-1}=\frac{2-p}{p^2}.$$

方差

$$D(X)=\frac{2-p}{p^2}-\frac{1}{p^2}=\frac{1-p}{p^2}.$$

Example 12.(超几何分布的期望和方差) 设 $(\Omega,\mathscr{F},P)$ 是概率空间, X 是其上的随机变量, 服从超几何分布

$$P(X=m)=\frac{C_M^mC_{N-M}^{n-m}}{C_N^n}.$$

则期望

$$E(X)=\sum_{m=1}^{\infty} m\frac{C_M^m C_{N-M}^{n-m}}{C_N^n}=\frac{M}{N}n.$$

$$E\left(X^2\right)=\sum_{m=1}^{\infty} m^2\frac{C_M^m C_{N-M}^{n-m}}{C_N^n}=\frac{M(M-1)n(n-1)+nM(N-1)}{N(N-1)}.$$

方差

$$D(X)=\frac{Mn(M-N)(n-N)}{N^2(N-1)}.$$

Example 13.(均匀分布的期望和方差) 设 $(\Omega,\mathscr{F},P)$ 是概率空间, X 是其上的随机变量, 服从均匀分布 $X\sim U(a,b)$. 则期望

$$E(X)=\int_a^b \frac{x}{b-a}\mathrm{d}x=\frac{a+b}{2}.$$

$$E\left(X^2\right)=\int_a^b \frac{x^2}{b-a}\mathrm{d}x=\frac{a^2+ab+b^2}{3}.$$

方差

$$D(X)=\frac{a^2+ab+b^2}{3}-\frac{a^2+2ab+b^2}{4}=\frac{(a-b)^2}{12}.$$

Example 14.(指数分布的期望和方差) 设 $(\Omega,\mathscr{F},P)$ 是概率空间, X 是其上的随机变量, 服从指数分布 $X\sim\mathscr{E}(\lambda)$. 则期望

$$E(X)=\int_0^{+\infty} x\lambda \mathrm{e}^{-\lambda x}\mathrm{d}x=\frac{1}{\lambda}.$$

$$E\left(X^2\right)=\int_0^{+\infty} x^2\lambda \mathrm{e}^{-\lambda x}\mathrm{d}x=\frac{2}{\lambda^2}.$$

方差

$$D(X)=\frac{2}{\lambda^2}-\frac{1}{\lambda^2}=\frac{1}{\lambda^2}.$$

Example 15.(Gamma 分布的期望和方差) 设 $(\Omega,\mathscr{F},P)$ 是概率空间, X 是其上的随机变量, 服从 Gamma 分布 $X\sim\Gamma(\alpha,\lambda)$. 则期望

$$E(X)=\int_0^{+\infty} x\mathrm{e}^{-\lambda x}\lambda^\alpha\frac{x^{\alpha-1}}{\Gamma(\alpha)}\mathrm{d}x=\frac{\alpha}{\lambda}.$$

$$E\left(X^2\right)=\int_0^{+\infty} x^2\mathrm{e}^{-\lambda x}\lambda^\alpha\frac{x^{\alpha-1}}{\Gamma(\alpha)}\mathrm{d}x=\frac{\alpha(\alpha+1)}{\lambda^2}.$$

方差

$$D(X)=\frac{\alpha(\alpha+1)}{\lambda^2}-\frac{\alpha^2}{\lambda^2}=\frac{\alpha}{\lambda^2}.$$

Example 16.(正态分布的期望和方差) 设 $(\Omega,\mathscr{F},P)$ 是概率空间, X 是其上的随机变量, 服从正态分布 $X\sim N(\mu,\sigma^2)$. 则期望

$$E(X)=\int_{-\infty}^{+\infty}x\frac{1}{\sigma\sqrt{2\pi}}\exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)\mathrm{d}x=\mu.$$

$$E\left(X^2\right)=\int_{-\infty}^{+\infty}x^2\frac{1}{\sigma\sqrt{2\pi}}\exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)\mathrm{d}x=\sigma^2+\mu^2.$$

方差

$$D(X)=\sigma^2+\mu^2-\mu^2=\sigma^2.$$

Theorem 25.(Chebyshev) 给定 $\alpha>0$, 设 $(\Omega,\mathscr{F},P)$ 是概率空间, X 是其上的随机变量, $\varphi(x)$ 是在 $(0,+\infty)$ 上非负严格单调上升的偶函数, 使得 $\varphi(X)$ 的数学期望存在, 则对任意 $\varepsilon>0$, 有不等式

$$P(|X|\geq\varepsilon)\leq\frac{E(\varphi(X))}{\varphi(\varepsilon)}.$$

特别地, 取随机变量 X 为 $X-E(X)$, $\varphi(x)=x^2$, 则有

$$P(|X-E(X)|\geq\varepsilon)\leq\frac{D(X)}{\varepsilon^2}.$$

Proof. 按期望的定义

$$\begin{aligned}E(\varphi(x))&=\int_{-\infty}^{+\infty}\varphi(x)\mathrm{d}F(x)\\&\geq\int_{|x|\geq\varepsilon}\varphi(x)\mathrm{d}F(x)\\&\geq\int_{|x|\geq\varepsilon}\varphi(\varepsilon)\mathrm{d}F(x)\\&=\varphi(\varepsilon)P(|X|\geq\varepsilon).\end{aligned}$$

□

***Definition 23.(变异系数)** 设 $(\Omega,\mathscr{F},P)$ 是概率空间, X 是其上的随机变量, 使得 X 和 X^2 的数学期望存在, 且 $E(X)\neq0$, 则称

$$C_v(X)=\frac{\sqrt{D(X)}}{E(X)}$$

为随机变量 X 的变异系数.

***Definition 24.(偏度与峰度)** 设 $(\Omega, \mathscr{F}, P)$ 是概率空间, X 是其上的随机变量, 使得 X 和 X^2 的数学期望存在, 且 $D(X) \neq 0$, 则称

$$E\left(\left(\frac{X - E(X)}{\sqrt{D(X)}}\right)^3\right) = \frac{E((X - E(X))^3)}{D(X)^{\frac{3}{2}}}$$

为随机变量 X 的偏度, 而

$$E\left(\left(\frac{X - E(X)}{\sqrt{D(X)}}\right)^4\right) - 3 = \frac{E((X - E(X))^4)}{D(X)^2} - 3$$

为随机变量 X 的峰度.

***Definition 25.(α-阶矩)** 给定 $\alpha > 0$. 设 $(\Omega, \mathscr{F}, P)$ 是概率空间, X 是其上的随机变量, 使得 X, X^2 和 $|X|^\alpha$ 的数学期望存在, 则称 $E(|X|^\alpha|$ 为随机变量 X 的 α-阶原点矩, $E(|X - E(X)|^\alpha|$ 为随机变量 X 的 α-阶中心矩.

Definition 26.(p-分位数) 设 $(\Omega, \mathscr{F}, P)$ 是概率空间, X 是其上的随机变量. 给定 $p \in [0, 1]$, 若存在 $x_0 \in \mathbb{R}$, 使得

$$P(X \geq x_0) \geq p, \quad P(X \leq x_0) \geq 1 - p,$$

则称 x_0 是随机变量 X 的分布的一个 p-分位数.

Chapter 3

多元概率论

3.1 随机向量与分布

Definition 27.(n 维随机向量) 设 $(\Omega_k, \mathscr{F}_k)(k = 1, 2, \ldots, n)$ 是可测空间, 记

$$\Omega = \prod_{k=1}^{n} \Omega_k, \quad \mathscr{F} = \sigma\left(\left\{\prod_{k=1}^{n} A_k \mid A_k \in \mathscr{F}_k\right\}\right).$$

X_k 是 $(\Omega_k, \mathscr{F}_k)$ 上的一个随机变量. 则称函数

$$\begin{array}{rccc} \mathbf{X}: & \Omega & \to & \mathbb{R}^n, \\ & \begin{bmatrix} \omega_1 \\ \omega_2 \\ \vdots \\ \omega_n \end{bmatrix} & \mapsto & \begin{bmatrix} X_1(\omega_1) \\ X_2(\omega_2) \\ \vdots \\ X_n(\omega_n) \end{bmatrix} \end{array}$$

是 $(\Omega, \mathscr{F}, P)$ 上的一个 n 维随机向量, 每个 X_k 称为该随机向量的分量.

Remark. 注意关于 Borel 代数的性质

$$\sigma\left(\prod_{k=1}^{n} \mathscr{B}_{\mathbb{R}}\right) = \mathscr{B}_{\mathbb{R}^n},$$

这给出了我们构造概率空间的方法, 只要分别构造随机变量 X_k 的概率空间即可.

Definition 28.(联合分布函数) 设 $(\Omega, \mathscr{F}, P)$ 是概率空间, $\mathbf{X}$ 为其上的一个 n 维随机向量. 定义

$$F(\mathbf{x}) = P\left(\bigcap_{k=1}^{n} (X_k \le x_k)\right) = P(\{\omega \in \Omega \mid X_k(\omega_k) \le x_k, 1 \le k \le n\})$$

为 X 的联合分布函数. 各个分量的分布函数

$$F_k(x) = P\left(X_k \le x_k\right) = P(\{\omega \in \Omega \mid X_k(\omega_k) \le x_k\})$$

称为 X_k 的边缘分布函数.

Remark. 依照定义, 边缘分布函数可以由

$$F_k(x_k) = \lim_{x_i \to +\infty, i \neq k} P(\{\omega \in \Omega \mid X_i(\omega_i) \leq x_i, 1 \leq i \leq n\}) = \lim_{x_i \to +\infty, i \neq k} F(\mathbf{x})$$

得到. 反之, 由边缘分布函数未必能得到联合分布函数.

****Theorem 26.(Lebesgue-Stieljes, 概率空间的存在性)** 设 $F : \mathbb{R}^n \to \mathbb{R}$ 对每个分量单调上升, 在任意一点处右连续且左极限存在, 满足

$$\lim_{x_k \to -\infty} F(\mathbf{x}) = 0, \quad \lim_{x_k \to +\infty} F(\mathbf{x}) = 1.$$

则存在概率空间 $(\Omega, \mathscr{F}, P)$ 以及其上的随机向量 $\mathbf{X}$, 使得 $F(\mathbf{x})$ 是 $\mathbf{X}$ 的联合分布函数.

Proof. 取样本空间 $\Omega = \mathbb{R}^n$, 事件域 $\mathscr{F} = \mathscr{B}_{\mathbb{R}^n}$, 我们定义区域

$$\prod_{k=1}^{n} (a_k, b_k]$$

上的概率为

$$P\left(\prod_{k=1}^{n} (a_k, b_k]\right) = F(\mathbf{b}) - F(\mathbf{a}).$$

注意到

$$\left\{\prod_{k=1}^{n} (a_k, b_k] \mid a_k, b_k \in \mathbb{R}, a_k \leq b_k, 1 \leq k \leq n\right\} \subseteq \mathcal{P}(\mathbb{R}^n)$$

对有限交封闭, 只要定义其补集的概率

$$\tilde{P}\left(\mathbb{R}^n \setminus \prod_{k=1}^{n} (a_k, b_k]\right) = 1 - (F(\mathbf{b}) - F(\mathbf{a})),$$

就在一个代数 $\mathscr{A}$ 上定义了概率 $\tilde{P}$. 我们证明这个代数生成的 σ-代数恰好为 $\mathscr{B}_{\mathbb{R}^n}$. 这只需要先将 $\mathbb{R}^n$ 中的开集表示为开长方体的并, 再将开长方体写为上述区域的并即可. 从而根据**Theorem 8.**可知此概率可以延拓为 $P : \mathscr{B}_{\mathbb{R}^n} \to \mathbb{R}$. 令随机变量 $X = \mathrm{id}_{\mathbb{R}^n}$ 即可. □

Definition 29.(联合密度函数) 设 $(\Omega, \mathscr{F}, P)$ 是概率空间, $\mathbf{X}$ 是其上的一个 n 维随机向量, $F(\mathbf{x})$ 为 $\mathbf{X}$ 的联合分布函数. 若存在 $f : \mathbb{R}^n \to [0, +\infty)$Lebesgue 可积, 且

$$\int_{t_k \leq x_k} f(\mathbf{t}) \mathrm{d}a = F(\mathbf{x}),$$

则称 $f(\mathbf{x})$ 是随机向量 $\mathbf{X}$ 的联合密度函数.

Proposition 27. 设 $(\Omega, \mathscr{F}, P)$ 是概率空间, $\mathbf{X}$ 是其上的一个 n 维随机向量, $f(\mathbf{x})$ 为 $\mathbf{X}$ 的联合密度函数. 则随机变量 X_k 的密度函数为

$$f_k(x_k) = \int_{x_i \in \mathbb{R}, i \neq k} f(\mathbf{x}) \mathrm{d}a.$$

Proof. 由于被积函数 $f(\mathbf{x})$ 非负, 根据 Tonelli 定理积分次序可交换, 即

$$\int_{-\infty}^{x_k}\int_{t_i\in\mathbb{R},i\neq k} f(\mathbf{t})\mathrm{d}a = \lim_{x_i\to+\infty,i\neq k}\int_{t_i\leq x_i} f(\mathbf{t})\mathrm{d}a = \lim_{x_i\to+\infty,i\neq k} F(\mathbf{x}) = F_k(x_k).$$

这就是随机变量 X_k 的边缘密度函数. □

Example 17.(多项式分布) 独立重复做随机试验 n 次, 每次实验有 m 个结果 $A_k(1\leq k\leq m)$, 达成每个结果的概率为 p_k. 取样本空间 $\Omega_k=\Omega_0$ 为 n 次试验的结果, 令随机变量 X_k 表示达成 A_k 的次数, 则

$$P\left(\bigcap_{k=1}^{m}(X_k=t_k)\right) = n!\prod_{k=1}^{m}\frac{p_k^{t_k}}{t_k!},\quad \sum_{k=1}^{n}t_k=n.$$

称 $\mathbf{X}$ 服从多项式分布.

Example 18.(超几何分布) 取样本空间 Ω 为从有 $N_k(1\leq k\leq m)$ 个 k 类产品的 N 个产品中不放回地取 n 个的结果, 令随机变量 X 表示取出 k 类产品的个数, 则

$$P\left(\bigcap_{k=1}^{m}(X_k=t_k)\right) = \frac{1}{C_N^n}\prod_{k=1}^{m}C_{N_k}^{t_k},\quad \sum_{k=1}^{m}t_k=n.$$

称 X 服从超几何分布.

Example 19.(n 维均匀分布) 取样本空间 $\Omega=\mathbb{R}^n$, $D\subseteq\mathbb{R}^n$ 可测, 其测度为 $\mu(D)$. 概率密度函数

$$f(\mathbf{x}) = \begin{cases}\frac{1}{\mu(D)}, & \mathbf{x}\in D,\\ 0, & \text{otherwise.}\end{cases}$$

依次定义 $F(\mathbf{x}), P, X$, 称此随机向量服从均匀分布 $X\sim U(D)$.

Example 20.(n 维 t 分布) 取样本空间 $\Omega=\mathbb{R}^n$, 概率密度函数

$$f(\mathbf{x}) = \frac{\Gamma\left(\frac{v+n}{2}\right)}{(v\pi)^2\Gamma\left(\frac{v}{2}\right)}\frac{1}{\sqrt{\det(\Sigma)}\left(1+\frac{1}{v}(\mathbf{x}-\mu)^T\Sigma^{-1}(\mathbf{x}-\mu)\right)^{\frac{v+n}{2}}},$$

其中 $v\in\mathbb{N}$ 为常数, 依次定义 $F(\mathbf{x}), P, X$, 称此随机向量服从 n 维 t 分布.

Definition 30.(n 维正态分布) 取样本空间 $\Omega=\mathbb{R}^n$, 概率密度函数

$$f(\mathbf{x}) = \frac{1}{(2\pi)^{\frac{n}{2}}\det(\Sigma)}\exp\left(-\frac{1}{2}(\mathbf{x}-\mu)^T\Sigma^{-1}(\mathbf{x}-\mu)\right),$$

其中 Σ 是 n 维正定矩阵, 依次定义 $F(x), P, \mathbf{X}$, 称此随机向量服从 n 维正态分布 $\mathbf{X}\sim N(\mu,\Sigma)$.

Example 21. 2 维正态分布 Σ 由 3 个参数决定, 于是可以表达为

$$\mu = \begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}, \quad \Sigma = \begin{bmatrix} \sigma_1^2 & \rho\sigma_1\sigma_2 \\ \rho\sigma_1\sigma_2 & \sigma_2^2 \end{bmatrix},$$

其逆矩阵

$$\Sigma^{-1} = \frac{1}{\sigma_1^2\sigma_2^2(1-\rho^2)} \begin{bmatrix} \sigma_2^2 & -\rho\sigma_1\sigma_2 \\ -\rho\sigma_1\sigma_2 & \sigma_1^2 \end{bmatrix} = \frac{1}{1-\rho^2} \begin{bmatrix} \sigma_1^{-2} & -\frac{\rho}{\sigma_1\sigma_2} \\ -\frac{\rho}{\sigma_1\sigma_2} & \sigma_2^{-2} \end{bmatrix}.$$

这样概率密度函数

$$\begin{aligned} f(\mathbf{x}) &= \frac{1}{(2\pi)^{\frac{n}{2}}\det(\Sigma)} \exp\left(-\frac{1}{2}(\mathbf{x}-\mu)^T\Sigma^{-1}(\mathbf{x}-\mu)\right) \\ &= \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} \exp\left(-\frac{\tilde{x_1}^2 - 2\rho\tilde{x_1}\tilde{x_2} + \tilde{x_2}^2}{2(1-\rho^2)}\right), \end{aligned}$$

其中

$$\tilde{x_1} = \frac{x_1-\mu_1}{\sigma_1}, \quad \tilde{x_2} = \frac{x_2-\mu_2}{\sigma_2}.$$

Example 22. 设 $(\Omega, \mathscr{F}, P)$ 是概率空间, $\mathbf{X} = (X_1, X_2)^T$ 是 2 维随机向量, 联合密度函数为 $f(x_1, x_2)$, 且其变限积分一致收敛. 考虑 $X_1 + X_2$ 和 X_1X_2 的概率密度函数. 依照定义

$$F_{X_1+X_2}(x) = \int_{x_1+x_2\le x} f(x_1,x_2)\mathrm{d}x_1\mathrm{d}x_2 = \int_{-\infty}^{+\infty}\left(\int_{-\infty}^{x-x_1} f(x_1,x_2)\mathrm{d}x_2\right)\mathrm{d}x_1.$$

由一致收敛, 两边对 x 求导可得

$$f_{X_1+X_2}(x) = \int_{-\infty}^{+\infty} f(x_1, x-x_1)\mathrm{d}x_1.$$

类似地也有

$$f_{X_1+X_2}(x) = \int_{-\infty}^{+\infty} f(x-x_2, x_2)\mathrm{d}x_2.$$

同样

$$F_{X_1X_2}(x) = \int_{x_1x_2\le x} f(x_1,x_2)\mathrm{d}x_1\mathrm{d}x_2.$$

按照 x_1 的范围展开为

$$\int_0^{+\infty}\left(\int_{-\infty}^{\frac{x}{x_1}} f(x_1,x_2)\mathrm{d}x_2\right)\mathrm{d}x_1 + \int_{-\infty}^{0}\left(\int_{\frac{x}{x_1}}^{+\infty} f(x_1,x_2)\mathrm{d}x_2\right)\mathrm{d}x_1.$$

对 x 求导即得

$$f_{X_1X_2}(x) = \int_0^{+\infty}\frac{1}{x_1}f\left(x_1,\frac{x}{x_1}\right)\mathrm{d}x_1 + \int_{-\infty}^{0}\frac{1}{-x_1}f\left(x_1,\frac{x}{x_1}\right)\mathrm{d}x_1.$$

整理即得

$$f_{X_1X_2}(x)=\int_{-\infty}^{+\infty}\frac{1}{|x_1|}f\left(x_1,\frac{x}{x_1}\right)\mathrm{d}x_1=\int_{-\infty}^{+\infty}\frac{1}{|x_2|}f\left(\frac{x}{x_2},x_2\right)\mathrm{d}x_2.$$

Theorem 28. 设 $(\Omega,\mathscr{F},P)$ 是概率空间, $\mathbf{X}$ 是 n 维随机向量, 联合密度函数为 $f_{\mathbf{X}}(\mathbf{x})$. 随机向量函数

$$\mathbf{Y}=\Phi(\mathbf{X})=\begin{bmatrix}\varphi_1(\mathbf{X})\\ \varphi_2(\mathbf{X})\\ \vdots\\ \varphi_n(\mathbf{X})\end{bmatrix},$$

使得每个 φ_k 连续可导且反函数存在. 则 $\mathbf{Y}$ 的联合密度函数为

$$f_{\mathbf{Y}}(\mathbf{y})=f_{\mathbf{X}}(\Phi^{-1}(\mathbf{y}))\det(J),$$

其中 J 是 Φ^{-1} 的 Jacobi 矩阵.

Proof. 依照定义

$$F_{\mathbf{Y}}(\mathbf{y})=\int_{\varphi_k(\mathbf{x})\le y_k}f_{\mathbf{X}}(\mathbf{x})\mathrm{d}a.$$

利用积分换元将 $\mathbf{x}$ 换为 $\Phi^{-1}(\mathbf{t})$, 即得

$$F_{\mathbf{Y}}(\mathbf{y})=\int_{\varphi_k(\Phi^{-1}(\mathbf{t}))\le y_k}f_{\mathbf{X}}(\Phi^{-1}(\mathbf{t}))\det(J)\mathrm{d}a=\int_{t_k\le y_k}f_{\mathbf{X}}(\Phi^{-1}(\mathbf{t}))\det(J)\mathrm{d}a.$$

根据定义**Definition 29.**即得

$$f_{\mathbf{Y}}(\mathbf{y})=f_{\mathbf{X}}(\Phi^{-1}(\mathbf{y}))\det(J).$$

□

Definition 30.(条件分布) 设 $(\Omega,\mathscr{F},P)$ 是概率空间, $\mathbf{X}$ 是 n 维随机向量, T 为随机变量, 联合密度函数为 $f_{\mathbf{X},T}(\mathbf{x},t)$. 如果对 $t_0\in\mathbb{R}$, 表达式

$$\frac{1}{f_T(t_0)}\int_{t_k\le x_k}f_{\mathbf{X},T}(\mathbf{x},t_0)\mathrm{d}a$$

有限存在, 则称为条件 $T=t_0$ 下 $\mathbf{X}$ 的联合分布, 记作 $F_{\mathbf{X},T=t_0}(\mathbf{x})$.

Remark. 依照定义, 这说明相应的联合密度函数

$$f_{\mathbf{X},T=t_0}(\mathbf{x})=\frac{f_{\mathbf{X},T}(\mathbf{x},t_0)}{f_T(t_0)}.$$

Proposition 29.(全概率公式) 设 $(\Omega,\mathscr{F},P)$ 是概率空间, $\mathbf{X}$ 是 n 维随机向量, T 为随机变量, 联合密度函数为 $f_{\mathbf{X},T}(\mathbf{x},t)$. 则对任意 $B\in\mathscr{B}_{\mathbb{R}^n}$, 有

$$P(\mathbf{X}\in B)=\int_{-\infty}^{+\infty}f_T(t)P(\mathbf{X}\in B\mid T=t)\mathrm{d}t.$$

Proof. 按照定义

$$P(\mathbf{X}\in B)=\int_B f_{\mathbf{X}}(\mathbf{x})\mathrm{d}a=\int_B\int_{-\infty}^{+\infty} f_{\mathbf{X},T}(\mathbf{x},t)\mathrm{d}t\mathrm{d}a=\int_B\int_{-\infty}^{+\infty} f_{\mathbf{X},T=t}(\mathbf{x})f_T(t)\mathrm{d}t\mathrm{d}a.$$

利用 Fubini 定理

$$P(\mathbf{X}\in B)=\int_{-\infty}^{+\infty} f_T(t)\int_B f_{\mathbf{X},T=t}(\mathbf{x})\mathrm{d}a\mathrm{d}t=\int_{-\infty}^{+\infty} f_T(t)P(\mathbf{X}\in B\mid T=t)\mathrm{d}t.$$

□

Definition 31.(顺序统计量) 设 $(\Omega,\mathscr{F},P)$ 是概率空间, $X_k(1\le k\le n)$ 是随机变量. 对每个 $\omega\in\Omega$, 将 $X_k(\omega)$ 的取值从小到大排序, 第 m 位的值记作 $X_{(m)}(\omega)$, 由此得到的随机变量 $X_{(m)}$ 称为 $X_k(1\le k\le n)$ 的第 m 顺序统计量.

Proposition 30. 设 $(\Omega,\mathscr{F},P)$ 是概率空间, $X_k(1\le k\le n)$ 是独立同分布的随机变量, 概率分布函数为 $F(x)$, 则第 m 顺序统计量的概率分布函数为

$$F_{(m)}(x)=\sum_{k=m}^{n}C_n^kF(x)^k(1-F(x))^{n-k}.$$

Proof. 记 $A_t(x)\subseteq\Omega$ 为使得 $X_k(\omega)(1\le k\le n)$ 中恰好有 t 个取值不大于 x 的 $\omega\in\Omega$ 的集合, 则

$$P(A_t(x))=C_n^tF(x)^t(1-F(x))^{n-t}.$$

于是

$$F_{(m)}(x)=\sum_{k=m}^{n}P(A_k(x))=\sum_{k=m}^{n}C_n^kF(x)^k(1-F(x))^{n-k}.$$

□

Proposition 31. 设 $(\Omega,\mathscr{F},P)$ 是概率空间, $X_k(1\le k\le n)$ 是独立同分布的随机变量, 概率密度函数为 $f(x)$, 则 $X_{(k)}$ 的联合密度函数为

$$f_{(\mathbf{X})}(\mathbf{x})=\begin{cases}n!\prod\limits_{k=1}^{n}f(x_k), & x_k\le x_{k+1},\\ 0, & \text{otherwise.}\end{cases}$$

Proof. 注意到当某个 $x_k>x_{k+1}$ 时概率为 0, 从而 $f_{(\mathbf{X})}(\mathbf{x})=0$, 而 $x_k\le x_{k+1}$ 恒成立时, 有

$$F_{(\mathbf{X})}(\mathbf{x})=P(X_{(k)}\le x_k,1\le k\le n)=n!P(X_k\le x_k,1\le k\le n).$$

利用独立性展开即得

$$F_{(\mathbf{X})}(\mathbf{x})=n!\prod_{k=1}^{n}F(x_k)=\int_{t_k\le x_k}n!\prod_{k=1}^{n}f(x_k)\mathrm{d}a,$$

依照定义即得

$$f_{(\mathbf{X})}(\mathbf{x}) = \begin{cases} n! \prod_{k=1}^{n} f(x_k), & x_k \le x_{k+1}, \\ 0, & \text{otherwise.} \end{cases}$$

□

3.2 期望与协方差

Definition 32.(数学期望) 设 $(\Omega, \mathscr{F}, P)$ 是概率空间, $\mathbf{X}$ 是其上的 n 维随机向量, 分布函数为 $F_{\mathbf{X}}(\mathbf{x})$, $\varphi : \mathbb{R}^n \to \mathbb{R}$ 是可测函数, 满足

$$\int_{-\infty}^{+\infty} |\varphi(\mathbf{x})| \mathrm{d}F_{\mathbf{X}}(\mathbf{x})$$

收敛. 则称

$$E(\varphi(\mathbf{X})) = \int_{\mathbb{R}^n} \varphi(\mathbf{x}) \mathrm{d}F_{\mathbf{X}}(\mathbf{x})$$

为随机向量函数 $\varphi(\mathbf{X})$ 的数学期望.

Remark. 这一定义直接推广了**Proposition 21.**的结果, 因而对 $n = 1$ 的情形适用.

Proposition 32.(期望的线性和可乘性) 设 $(\Omega, \mathscr{F}, P)$ 是概率空间, X, Y 是其上的随机变量, 使得两者的期望均存在, 则对任意 $a, b \in \mathbb{R}$, 有

$$E(aX + bY) = aE(X) + bE(Y).$$

若进一步有 X 与 Y 独立, 则

$$E(XY) = E(X)E(Y).$$

Proof. 按照定义

$$\begin{aligned} E(aX + bY) &= \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} (ax + by) \mathrm{d}F_{X,Y}(x, y) \\ &= a \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} x \mathrm{d}F_{X,Y}(x, y) + b \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} y \mathrm{d}F_{X,Y}(x, y) \\ &= a \int_{-\infty}^{+\infty} x \mathrm{d}F_X(x) + b \int_{-\infty}^{+\infty} y \mathrm{d}F_Y(y) \\ &= aE(X) + bE(Y). \end{aligned}$$

若 X 与 Y 独立, 则

$$E(XY) = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} xy \mathrm{d}F_{X,Y}(x, y) = \int_{-\infty}^{+\infty} x \mathrm{d}F_X(x) \int_{-\infty}^{+\infty} y \mathrm{d}F_Y(y) = E(X)E(Y).$$

□

Corollary 33.(方差的线性) 设 $(\Omega, \mathscr{F}, P)$ 是概率空间, X, Y 是其上相互独立的随机变量, 使得 X, Y, X^2, Y^2 的期望均存在, 则对任意 $a, b \in \mathbb{R}$, 有

$$D(aX + bY) = a^2 D(X) + b^2 D(Y).$$

Proof. 将 $Z = aX + bY$ 视作随机变量, 则利用**Corollary 23.**可得

$$D(aX+bY) = E\left((aX+bY)^2\right) - E(aX+bY)^2.$$

根据**Proposition 32.**的结果

$$E\left((aX+bY)^2\right) = a^2E\left(X^2\right) + 2abE(X)E(Y) + b^2E\left(Y^2\right),$$

$$E(aX+bY)^2 = a^2E(X)^2 + 2abE(X)E(Y) + b^2E(Y)^2.$$

从而

$$D(aX+bY) = a^2E\left(X^2\right) - a^2E(X)^2 + b^2E\left(Y^2\right) - b^2E(Y)^2 = a^2D(X) + b^2D(Y).$$

□

Definition 33.(协方差) 设 $(\Omega, \mathscr{F}, P)$ 是概率空间, X, Y 是其上的随机变量, 使得 X, Y 的期望存在. 如果期望

$$E((X - E(X))(Y - E(Y)))$$

存在, 则称为 X 与 Y 的协方差, 记作 $\mathrm{Cov}(X, Y)$. 若 $\mathbf{X}$ 是 n 维随机向量, 两两协方差存在, 则称

$$\Sigma(\mathbf{X}) = \begin{bmatrix} \mathrm{Cov}(X_1, X_1) & \mathrm{Cov}(X_1, X_2) & \cdots & \mathrm{Cov}(X_1, X_n) \\ \mathrm{Cov}(X_2, X_1) & \mathrm{Cov}(X_2, X_2) & \cdots & \mathrm{Cov}(X_2, X_n) \\ \vdots & \vdots & \ddots & \vdots \\ \mathrm{Cov}(X_n, X_1) & \mathrm{Cov}(X_n, X_2) & \cdots & \mathrm{Cov}(X_n, X_n) \end{bmatrix}$$

为随机向量 $\mathbf{X}$ 的协方差矩阵.

Remark. 如果 X^2, XY, Y^2 的期望也存在, 则利用期望的线性可得

$$\mathrm{Cov}(X, Y) = E(XY) - E(X)E(Y).$$

若 X 与 Y 独立, 则恰有 $\mathrm{Cov}(X, Y) = 0$. 依照方差的定义直接可得 $\mathrm{Cov}(X, X) = D(X)$.

Definition 34.(相关系数) 设 $(\Omega, \mathscr{F}, P)$ 是概率空间, X, Y 是其上的随机变量, 使得 X, Y 的期望和方差存在. 如果期望

$$E\left(\frac{X - E(X)}{\sqrt{D(X)}}\frac{Y - E(Y)}{\sqrt{D(Y)}}\right) = \frac{\mathrm{Cov}(X, Y)}{\sqrt{D(X)D(Y)}}$$

存在, 则称为 X 与 Y 的相关系数, 记作 $\rho(X,Y)$.

Remark. 相关系数可以看做标准化后的随机变量的协方差.

Example 23. 对Example 21.给出的概率密度函数, 计算

$$E(X_1X_2)=\int_{-\infty}^{+\infty}\int_{-\infty}^{+\infty}\frac{x_1x_2}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}}\exp\left(-\frac{\tilde{x_1}^2-2\rho\tilde{x_1}\tilde{x_2}+\tilde{x_1}^2}{2(1-\rho^2)}\right)\mathrm{d}x_1\mathrm{d}x_2.$$

换元得到

$$E(X_1X_2)=\int_{-\infty}^{+\infty}\int_{-\infty}^{+\infty}\frac{(\sigma_1\tilde{x_1}+\mu_1)(\sigma_2\tilde{x_2}+\mu_2)}{2\pi\sqrt{1-\rho^2}}\exp\left(-\frac{\tilde{x_1}^2-2\rho\tilde{x_1}\tilde{x_2}+\tilde{x_2}^2}{2(1-\rho^2)}\right)\mathrm{d}\tilde{x_1}\mathrm{d}\tilde{x_2}.$$

利用 Gauss 积分的结果容易得到

$$\int_{-\infty}^{+\infty}\mathrm{e}^{-(ax^2+bx+c)}\mathrm{d}x=\int_{-\infty}^{+\infty}\exp\left(-a\left(x+\frac{b}{2a}\right)^2+\frac{b^2}{4a}-c\right)\mathrm{d}x=\sqrt{\frac{\pi}{a}}\exp\left(\frac{b^2}{4a}-c\right).$$

而显然有

$$\int_{-\infty}^{+\infty}(2ax+b)\mathrm{e}^{-(ax^2+bx+c)}\mathrm{d}x=0,$$

于是

$$\int_{-\infty}^{+\infty}x\mathrm{e}^{-(ax^2+bx+c)}\mathrm{d}x=-\frac{b}{2a}\sqrt{\frac{\pi}{a}}\exp\left(\frac{b^2}{4a}-c\right).$$

代入计算内层积分

$$E(X_1X_2)=\frac{1}{\sqrt{2\pi}}\int_{-\infty}^{+\infty}(\rho\sigma_1\tilde{x_2}+\mu_1)(\sigma_2\tilde{x_2}+\mu_2)\exp\left(-\frac{\tilde{x_2}^2}{2}\right)\mathrm{d}\tilde{x_2}.$$

利用分部积分

$$\int_{-\infty}^{+\infty}x^2\mathrm{e}^{-ax^2}\mathrm{d}x=-\frac{1}{2a}\int_{-\infty}^{+\infty}x\mathrm{d}\mathrm{e}^{-ax^2}=\frac{1}{2a}\int_{-\infty}^{+\infty}\mathrm{e}^{-ax^2}\mathrm{d}x=\frac{1}{2a}\sqrt{\frac{\pi}{a}},$$

于是

$$E(X_1X_2)=\frac{1}{\sqrt{2\pi}}\left(\rho\sigma_1\sigma_2\sqrt{2\pi}+(\rho\sigma_1\mu_2+\sigma_2\mu_1)0+\mu_1\mu_2\sqrt{2\pi}\right)=\rho\sigma_1\sigma_2+\mu_1\mu_2.$$

类似地边缘密度函数

$$f_{X_1}(x_1)=\int_{-\infty}^{+\infty}\frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}}\exp\left(-\frac{\tilde{x_1}^2-2\rho\tilde{x_1}\tilde{x_2}+\tilde{x_1}^2}{2(1-\rho^2)}\right)\mathrm{d}x_2,$$

计算得

$$f_{X_1}(x_1)=\frac{1}{\sqrt{2\pi}\sigma_1}\exp\left(-\frac{(x_1-\mu_1)^2}{2\sigma_1^2}\right)$$

是正态分布, 从而 $E(X_1)=\mu_1$, $D(X_1)=\sigma_1^2$. 于是相关系数

$$\rho(X_1,X_2)=\frac{E(X_1X_2)-E(X_1)E(X_2)}{\sqrt{D(X_1)D(X_2)}}=\frac{\rho\sigma_1\sigma_2+\mu_1\mu_2-\mu_1\mu_2}{\sigma_1\sigma_2}=\rho.$$

Proposition 34. 设 $(\Omega,\mathscr{F},P)$ 是概率空间, X,Y 是其上的随机变量, 使得相关系数 $\rho(X,Y)$ 存在, 则 $|\rho(X,Y)|\leq 1$, 且对任意 $a,b\in\mathbb{R}$, 有 $\rho(X,Y)=\rho(aX,bY)$.

Proof. 利用积分的 Cauchy-Schwarz 不等式, 容易得到

$$E(XY)^2=\left(\int_{\mathbb{R}^2}xy\mathrm{d}F(x,y)\right)^2\leq\int_{\mathbb{R}^2}x^2\mathrm{d}F(x,y)\int_{\mathbb{R}^2}y^2\mathrm{d}F(x,y)=E\left(X^2\right)E\left(Y^2\right).$$

于是

$$\mathrm{Cov}(X,Y)^2=E((X-E(X))(Y-E(Y)))^2\leq D(X)D(Y).$$

这就说明了

$$\rho(X,Y)^2\leq 1\implies|\rho(X,Y)|\leq 1.$$

依照协方差的定义 $\mathrm{Cov}(aX,bY)=ab\,\mathrm{Cov(X,Y)}$, 而方差 $D(aX)=a^2D(X)$, $D(bY)=b^2D(Y)$, 代入即得 $\rho(X,Y)=\rho(aX,bY)$. □

3.3 大数定律

Definition 35.(随机变量序列的收敛) 设 $(\Omega, \mathscr{F}, P)$ 是概率空间, X_n 是其上的随机变量序列, X 是一个随机变量或常数.

1. 如果对任意 $\omega \in \Omega \setminus N$, 其中 N 是一个零测集, 都有

$$\lim_{n\to\infty} X_n(\omega) = X(\omega),$$

称 $\{X_n\}$ 几乎处处收敛 (a.e.) 到 X.

2. 如果对任意 $\varepsilon > 0$, 有

$$\lim_{n\to\infty} P\left(\{\omega \in \Omega \mid |X_n(\omega) - X(\omega)| < \varepsilon\}\right) = 1,$$

称 $\{X_n\}$ 依概率收敛 (pr.) 到 X.

3. 如果对某个 $\alpha > 0$, 有

$$\lim_{n\to\infty} E(|X_n - X|^\alpha) = 0,$$

称 $\{X_n\}$ 满足 L^α 收敛或 α 阶矩收敛到 X.

Theorem 35. 设 $(\Omega, \mathscr{F}, P)$ 是概率空间, X_n 是其上的随机变量序列, X 是一个随机变量或常数. 则 $\{X_n\}$ 几乎处处收敛到 X 当且仅当对任意 $\varepsilon > 0$, 有

$$\lim_{m\to\infty} P(\{\omega \in \Omega \mid |X_n(\omega) - X(\omega)| < \varepsilon, n \geq m\}) = 1.$$

Proof. (必要性) 定义

$$A_m(\varepsilon) = \bigcap_{n=m}^{\infty} \{|X_n - X| < \varepsilon\}.$$

则这是一个单调上升的集合序列, 依照几乎处处收敛的定义, 对任意 $\omega \in \Omega \setminus N$, 存在 $m(\omega, \varepsilon) \in \mathbb{N}^*$, 使得对任意 $n \geq m(\omega, \varepsilon)$, 都有

$$|X_n(\omega) - X(\omega)| < \varepsilon.$$

于是任意 $\omega \in \Omega \setminus N$ 都在某个 $A_{m(\omega,\varepsilon)}(\varepsilon)$ 中, 于是

$$\Omega \setminus N \subseteq \bigcup_{m=1}^{\infty} A_m(\varepsilon).$$

利用概率的连续性 (**Proposition 3.**), 单调性可得

$$P(\Omega \setminus N) \leq P\left(\bigcup_{m=1}^{\infty} A_m(\varepsilon)\right) = \lim_{m\to\infty} P(A_m(\varepsilon)) \leq 1,$$

注意到 N 是零测集, 于是 $P(\Omega \setminus N) = 1$, 这就证明了

$$\lim_{m\to\infty} P(A_m(\varepsilon)) = 1.$$

(充分性) 定义

$$A(\varepsilon) = \bigcup_{m=1}^{\infty} A_m(\varepsilon),$$

则同样根据连续性可得 $P(A(\varepsilon)) = 1$. 对任意 $\omega \in A(\varepsilon)$, 按定义和单调上升, 存在一个 $m(\omega, \varepsilon) \in \mathbb{N}^*$, 当 $n \geq m(\omega, \varepsilon)$ 时, 有 $\omega \in A_n(\varepsilon)$, 即

$$|X_n(\omega) - X(\omega)| < \varepsilon.$$

现在取

$$\varepsilon = \frac{1}{p}, \quad A = \bigcap_{p=1}^{\infty} A\left(\frac{1}{p}\right),$$

则根据连续性

$$P(A) = \lim_{p\to\infty} P\left(A\left(\frac{1}{p}\right)\right) = 1,$$

这说明 $N = \Omega \setminus A$ 是零测集, 且对任意 $\omega \in \Omega \setminus N = A$ 和任意 $\varepsilon > 0$, 根据交集的性质必有

$$\omega \in A\left(\frac{1}{[\varepsilon^{-1}] + 1}\right),$$

这说明只要 $n > m(\omega, ([\varepsilon^{-1}] + 1)^{-1})$, 就有

$$|X_n(\omega) - X(\omega)| < \frac{1}{[\varepsilon^{-1}] + 1} < \varepsilon.$$

□

Remark. 作为推论, 如果 $\{X_n\}$ 几乎处处收敛到 X, 则 $\{X_n\}$ 依概率收敛到 X.

Theorem 36. 设 $(\Omega, \mathscr{F}, P)$ 是概率空间, X_n 是其上的随机变量序列, X 是一个随机变量或常数. 如果 $\{X_n\}$ 按 L^α 收敛到 X, 则 $\{X_n\}$ 依概率收敛到 X.

Proof. 在 Chebyshev 不等式 (**Theorem 25.**) 中取随机变量为 $X_n - X$, $\varphi(x) = |x|^\alpha$, 即得

$$P(|X_n - X| \geq \varepsilon) \leq \frac{E(|X_n - X|^\alpha)}{\varepsilon^\alpha}.$$

按照 L^α 收敛的定义, 取极限即得

$$\lim_{n\to\infty} P(|X_n - X| \geq \varepsilon) = 0.$$

□

Definition 36.(大数定律) 设 $(\Omega, \mathscr{F}, P)$ 是概率空间, X_n 是其上的随机变量序列, 随机变量

$$\overline{X_n} = \frac{1}{n}\sum_{k=1}^{n} X_k.$$

如果 $\overline{X_n}$ 依概率收敛到 $E(\overline{X_n})$, 则称 $\{X_n\}$ 满足弱大数定律. 如果 $\overline{X_n}$ 几乎处处收敛到 $E(\overline{X_n})$, 则称 $\{X_n\}$ 满足强大数定律.

Remark. 根据收敛的性质, 满足强大数定律必然满足弱大数定律.

Theorem 37.(Markov) 设 $(\Omega, \mathscr{F}, P)$ 是概率空间, X_n 是其上的随机变量序列. 若

$$\lim_{n\to\infty} \frac{1}{n^2} D\left(\sum_{k=1}^{n} X_k\right) = 0,$$

则 $\{X_n\}$ 满足弱大数定律.

Proof. 对任意 $\varepsilon > 0$, 利用 Chebyshev 不等式可得

$$P(|\overline{X_n} - E(\overline{X_n})| \geq \varepsilon) \leq \frac{D(\overline{X_n})}{\varepsilon^2}.$$

利用随机变量方差的性质

$$D(\overline{X_n}) = D\left(\frac{1}{n}\sum_{k=1}^{n} X_k\right) = \frac{1}{n^2} D\left(\sum_{k=1}^{n} X_k\right).$$

取极限即得

$$0 \leq \lim_{n\to\infty} P(|\overline{X_n} - E(\overline{X_n})| \geq \varepsilon) \leq 0.$$

□

Theorem 38.(Chebyshev) 设 $(\Omega, \mathscr{F}, P)$ 是概率空间, X_n 是其上的随机变量序列. 若 X_k 两两独立且方差 $D(X_k)$ 一致有界, 则 $\{X_n\}$ 满足弱大数定律.

Proof. 对任意 $\varepsilon > 0$, 利用 Chebyshev 不等式可得

$$P(|\overline{X_n} - E(\overline{X_n})| \geq \varepsilon) \leq \frac{D(\overline{X_n})}{\varepsilon^2}.$$

利用独立随机变量方差的性质和一致有界

$$D(\overline{X_n}) = D\left(\frac{1}{n}\sum_{k=1}^{n} X_k\right) = \frac{1}{n^2}\sum_{k=1}^{n} D(X_k) \leq \frac{nM}{n^2} = \frac{M}{n}.$$

取极限即得

$$0 \leq \lim_{n\to\infty} P(|\overline{X_n} - E(\overline{X_n})| \geq \varepsilon) \leq 0.$$

□

Theorem 39.(Khinchin) 设 $(\Omega, \mathscr{F}, P)$ 是概率空间, X_n 是其上的随机变量序列. 若 X_k 独立同分布, 且均值 $E(X_k) = \mu$ 有限存在, 则 $\{X_n\}$ 满足弱大数定律.

Proof. 构造随机变量

$$Y_n(\omega) = \begin{cases} X_n(\omega), & |X_n(\omega)| \leq n, \\ 0, & |X_n(\omega)| > n. \end{cases}$$

则 $P(|X_n| > n) = P(X_n \neq Y_n)$. 注意到期望有限存在, 根据**Proposition 20.**可知

$$E(X_n) = \sum_{n=1}^{\infty} P(|X_n| > n).$$

这里不区分下标 n 是因为独立同分布. 于是

$$\lim_{n\to\infty} P(|X_n| > n) = \lim_{n\to\infty} P(X_n \neq Y_n) = 0,$$

因此我们只要对 $\{Y_n\}$ 证明弱大数定律即可. 根据 Chebyshev 不等式有

$$P\left(\left|\overline{Y_n} - E\left(\overline{Y_n}\right)\right| \geq \varepsilon\right) \leq \frac{1}{\varepsilon^2} D\left(\overline{Y_n} - E\left(\overline{Y_n}\right)\right) = \frac{1}{n^2\varepsilon^2} \sum_{k=1}^{n} D(Y_k).$$

有估计

$$D(Y_k) = E\left(Y_k^2\right) - E(Y_k)^2 \leq E\left(Y_k^2\right) = \int_{|x|\leq k} x^2 \mathrm{d}F(x).$$

为了得到一个精细的上界, 取一个数列 $\{a_n\}$, 使得

$$0 < a_n < n, \quad \lim_{n\to\infty} a_n = \infty, \quad \lim_{n\to\infty} \frac{a_n}{n} = 0,$$

例如 $a_n = [\ln n]$. 此时有

$$\begin{aligned}
&\sum_{k=1}^{n} \int_{|x|\leq k} x^2 \mathrm{d}F(x) \\
=&\sum_{k=1}^{a_n} \int_{|x|\leq k} x^2 \mathrm{d}F(x) + \sum_{k=a_n+1}^{n} \int_{|x|\leq k} x^2 \mathrm{d}F(x) \\
\leq&\sum_{k=1}^{a_n} a_n \int_{|x|\leq a_n} |x| \mathrm{d}F(x) + \sum_{k=a_n+1}^{n} a_n \int_{|x|\leq a_n} |x| \mathrm{d}F(x) + \sum_{k=a_n+1}^{n} n \int_{a_n<|x|\leq n} |x| \mathrm{d}F(x) \\
\leq&n a_n \int_{-\infty}^{+\infty} |x| \mathrm{d}F(x) + n^2 \int_{|x|>a_n} |x| \mathrm{d}F(x).
\end{aligned}$$

这就说明

$$\lim_{n\to\infty} \frac{1}{n^2} \sum_{k=1}^{n} D(Y_k) \leq \lim_{n\to\infty} \frac{a_n}{n}\mu + \lim_{n\to\infty} \int_{|x|>a_n} |x| \mathrm{d}F(x) = 0,$$

进而

$$\lim_{n\to\infty} P\left(\left|\overline{Y_n} - E\left(\overline{Y_n}\right)\right| \geq \varepsilon\right) = 0.$$

□

Theorem 40.(Kronecker) 设 $\{x_n\} \subseteq \mathbb{R}$, 正实数列 $\{a_n\}$ 单调上升趋于无穷, 若级数

$$\sum_{n=1}^{\infty} \frac{x_n}{a_n}$$

收敛, 则有

$$\lim_{n\to\infty} \frac{1}{a_n} \sum_{k=1}^{n} x_k = 0.$$

Proof. 定义

$$S_n = \sum_{k=1}^{n} \frac{x_k}{a_k},$$

则 $\{S_n\}$ 极限存在, 记为 S, 从而对任意 $\varepsilon > 0$, 存在 $N(\varepsilon) \in \mathbb{N}^*$, 当 $n > N(\varepsilon)$ 时, $|S_n - S| < \varepsilon$. 补充定义 $S_0 = 0$, 利用 Abel 变换可得

$$\frac{1}{a_n} \sum_{k=1}^{n} x_k = \frac{1}{a_n} \sum_{k=1}^{n} a_k(S_k - S_{k-1}) = S_n - \frac{1}{a_n} \sum_{k=1}^{n-1} (a_{k+1} - a_k) S_k.$$

由于 $\{a_n\}$ 单调上升, 有

$$\left| S - \frac{1}{a_n} \sum_{k=N(\varepsilon)+1}^{n-1} (a_{k+1} - a_k) S_k \right| = \left| \frac{1}{a_n} \sum_{k=N(\varepsilon)+1}^{n-1} (a_{k+1} - a_k)(S_k - S) + \frac{a_{N(\varepsilon)+1}}{a_n} S \right|,$$

由三角不等式上式有上界

$$\left(1 - \frac{a_{N(\varepsilon)+1}}{a_n}\right) \varepsilon + \frac{a_{N(\varepsilon)+1}}{a_n} |S|.$$

于是

$$\lim_{n\to\infty} \left| \frac{1}{a_n} \sum_{k=1}^{n} x_k \right| \leq \lim_{n\to\infty} \left(\left(1 - \frac{a_{N(\varepsilon)+1}}{a_n}\right) \varepsilon + \frac{a_{N(\varepsilon)+1}}{a_n} |S| \right) = \varepsilon.$$

根据 ε 的任意性即得

$$\lim_{n\to\infty} \frac{1}{a_n} \sum_{k=1}^{n} x_k = 0.$$

□

Theorem 41.(Kolmogorov) 设 $(\Omega, \mathscr{F}, P)$ 是概率空间, X_n 是其上相互独立的随机变量序列, 且各项方差有限存在. 定义

$$S_n = \sum_{k=1}^{n} (X_k - E(X_k)),$$

则对任意 $\varepsilon > 0$, 有

$$P\left(\max_{1\leq k\leq n} \{|S_k|\} \geq \varepsilon \right) \leq \frac{1}{\varepsilon^2} \sum_{k=1}^{n} D(X_k).$$

Proof. 定义

$$A_0 = \emptyset, \quad A_k = \{\omega \in \Omega \mid |S_k(\omega)| \geq \varepsilon\},$$

而 B_k 为 $\Omega \setminus A_i (0 \leq i \leq k-1)$ 与 A_k 之交集, 则

$$A = \left\{\omega \in \Omega \mid \max_{1 \leq k \leq n} \{|S_k(\omega)|\} \geq \varepsilon\right\} = \sum_{k=1}^{n} B_k.$$

于是

$$E\left(S_n^2\right) \geq E\left(S_n^2 I_A\right) = \sum_{k=1}^{n} E\left((S_n - S_k + S_k)^2 I_{B_k}\right).$$

注意到 I_{B_k}, S_k 和 $S_n - S_k$ 独立, 有

$$E\left((S_n - S_k + S_k)^2 I_{B_k}\right) = E\left((S_n - S_k)^2 I_{B_k}\right) + 2E(S_n - S_k)E(S_k I_{B_k}) + E\left(S_k^2 I_{B_k}\right),$$

其中

$$E(S_n - S_k) = E(S_n) - E(S_k) = 0 - 0 = 0.$$

从而

$$E\left(S_n^2\right) \geq \sum_{k=1}^{n} E\left(S_k^2 I_{B_k}\right) \geq \varepsilon^2 \sum_{k=1}^{n} P(B_k) = \varepsilon^2 P(A).$$

这就说明了

$$P(A) \leq \frac{1}{\varepsilon^2} E\left(S_n^2\right) = \frac{1}{\varepsilon^2}\left(D(S_n) + E(S_n)^2\right) = \frac{1}{\varepsilon^2} D(S_n) = \frac{1}{\varepsilon^2} \sum_{k=1}^{n} D(X_k).$$

□

Theorem 42.(Kolmogorov) 设 $(\Omega, \mathscr{F}, P)$ 是概率空间, X_n 是其上相互独立的随机变量序列. 对某个定常数 $A > 0$, 定义随机变量

$$Y_n(\omega) = \begin{cases} X_n(\omega), & |X_n(\omega)| \leq A, \\ 0, & |X_n(\omega)| > A. \end{cases}$$

若级数

1. $$\sum_{n=1}^{\infty} P(|X_n| > A) = \sum_{n=1}^{\infty} P(X_n \neq Y_n),$$

2. $$\sum_{n=1}^{\infty} E(Y_n),$$

3. $$\sum_{n=1}^{\infty} D(Y_n)$$

均收敛, 则 X_n 的级数和收敛.

Proof. 根据**Theorem 41.**有

$$P\left(\max_{n_1\le k\le n_2}\left\{\left|\sum_{j=n_1}^{k}(Y_j-E(Y_j))\right|\right\}\le\frac{1}{m}\right)\ge 1-m^2\sum_{j=n_1}^{n_2}D(Y_j).$$

利用方差的收敛性, 依次取极限 $n_2\to\infty$ 和 $n_1\to\infty$ 可得概率收敛到 1, 于是

$$\sum_{n=1}^{\infty}(Y_n-E(Y_n))$$

收敛. 注意到期望也收敛, 从而求和可知级数 Y_n 收敛, 进而由于 $P(X_n\neq Y_n)$ 趋于 0 可知级数 X_n 收敛. □

Theorem 43.(Kolmogorov-Marcinkiewicz-Zygmund) 设 $(\Omega,\mathscr{F},P)$ 是概率空间, X_n 是其上相互独立的随机变量序列, 均值均为 0. 正实数列 $\{a_n\}$ 单调上升趋于无穷, $\varphi:\mathbb{R}\to\mathbb{R}$ 是非负连续偶函数, 使得 $\frac{\varphi(x)}{|x|}$ 单调上升, $\frac{\varphi(x)}{x^2}$ 单调下降, 且级数

$$\sum_{n=1}^{\infty}\frac{E(\varphi(X_n))}{\varphi(a_n)}$$

收敛, 则 $\{X_n\}$ 满足强大数定律.

Proof. 构造随机变量

$$Y_n(\omega)=\begin{cases}X_n(\omega), & |X_n(\omega)|\le a_n,\\ 0, & |X_n(\omega)|>a_n.\end{cases}$$

则由 $\frac{\varphi(x)}{x^2}$ 单调下降可得

$$\sum_{n=1}^{\infty}E\left(\frac{Y_n^2}{a_n^2}\right)=\sum_{n=1}^{\infty}\int_{|x|\le a_n}\frac{x^2}{a_n^2}\mathrm{d}F_n(x)\le\sum_{n=1}^{\infty}\int_{|x|\le a_n}\frac{\varphi(x)}{\varphi(a_n)}\mathrm{d}F_n(x),$$

利用**Corollary 23.**放缩得

$$\sum_{n=1}^{\infty}D\left(\frac{Y_n}{a_n}\right)\le\sum_{n=1}^{\infty}\int_{|x|\le a_n}\frac{\varphi(x)}{\varphi(a_n)}\mathrm{d}F_n(x)\le\sum_{n=1}^{\infty}\frac{E(\varphi(X_n))}{\varphi(a_n)}$$

收敛. 注意到

$$|Y_n-E(Y_n)|\le|Y_n|+|E(Y_n)|\le 2a_n\implies\left|\frac{Y_n-E(Y_n)}{a_n}\right|\le 2,$$

在**Theorem 42.**中取 $A=2$ 即知级数和

$$\sum_{n=1}^{\infty}\frac{Y_n-E(Y_n)}{a_n}$$

收敛. 作估计

$$\sum_{n=1}^{\infty}\frac{|E(Y_n)|}{a_n}=\sum_{n=1}^{\infty}\frac{1}{a_n}\left|\int_{|x|\le a_n}x\mathrm{d}F_n(x)\right|,$$

注意到 X_n 的均值为 0, 有

$$\sum_{n=1}^{\infty}\frac{|E(Y_n)|}{a_n}=\sum_{n=1}^{\infty}\frac{1}{a_n}\left|\int_{|x|>a_n}x\mathrm{d}F_n(x)\right|\le\sum_{n=1}^{\infty}\int_{|x|>a_n}\frac{|x|}{a_n}\mathrm{d}F_n(x).$$

由于 $\frac{\varphi(x)}{|x|}$ 单调上升, 有

$$\sum_{n=1}^{\infty}\frac{|E(Y_n)|}{a_n}\le\sum_{n=1}^{\infty}\int_{|x|>a_n}\frac{\varphi(x)}{\varphi(a_n)}\mathrm{d}F_n(x)\le\sum_{n=1}^{\infty}\frac{E(\varphi(X_n))}{\varphi(a_n)}$$

收敛, 于是级数和 $\frac{Y_n}{a_n}$ 几乎处处收敛, 进而级数和 $\frac{X_n}{a_n}$ 几乎处处收敛. 利用**Theorem 40.**可知 $\{X_n\}$ 满足强大数定律. □

Remark. 取 $\varphi(x)=|x|^p$ 和 $a_n=n$, 其中 $p=2$ 的情形由 Kolmogorov 给出, $1\le p<2$ 的情形由 Marcinkiewicz 和 Zygmund 给出.

Theorem 44.(Kolmogorov) 设 $(\Omega,\mathscr{F},P)$ 是概率空间, X_n 是其上的随机变量序列. 若 X_k 独立同分布, 且均值 $E(X_k)=\mu$ 有限存在, 则 $\{X_n\}$ 满足强大数定律.

Proof. 构造随机变量

$$Y_n(\omega)=\begin{cases}X_n(\omega), & |X_n(\omega)|\le n,\\ 0, & |X_n(\omega)|>n.\end{cases}$$

注意到

$$\sum_{n=1}^{\infty}\frac{E\left(Y_n^2\right)}{n^2}=\sum_{n=1}^{\infty}\frac{1}{n^2}\int_{|x|\le n}x^2\mathrm{d}F(x),$$

作估计

$$\begin{aligned}\sum_{n=1}^{\infty}\frac{1}{n^2}\int_{|x|\le n}x^2\mathrm{d}F(x)&=\sum_{n=1}^{\infty}\frac{1}{n^2}\sum_{j=1}^{n}\int_{j-1<|x|\le j}x^2\mathrm{d}F(x)\\&=\sum_{j=1}^{\infty}\left(\sum_{n=j}^{\infty}\frac{1}{n^2}\int_{j-1<|x|\le j}x^2\mathrm{d}F(x)\right)\\&\le\sum_{j=1}^{\infty}\left(\frac{C}{j}j\int_{j-1<|x|\le j}|x|\mathrm{d}F(x)\right)\\&\le C\mu.\end{aligned}$$

根据**Theorem 43.**的结果即知 $\{X_n\}$ 满足强大数定律. □

Remark. 结合**Theorem 35.**立即得到**Theorem 39.**作为推论.

Chapter 4

中心极限定理

4.1 特征函数理论

Definition 37.(特征函数) 设 $(\Omega, \mathscr{F}, P)$ 是概率空间, X 是其上的随机变量. 定义

$$\psi_X(t) = E\left(\mathrm{e}^{\mathrm{i}tX}\right) = \int_{-\infty}^{+\infty} \mathrm{e}^{\mathrm{i}tx}\mathrm{d}F_X(x)$$

为随机变量 X 的特征函数.

Remark. 这实际上就是 Fourier 反变换, 从而常用留数定理计算一些积分. 如果概率密度函数 $f_X(x)$ 存在, 即

$$\psi_X(t) = E\left(\mathrm{e}^{\mathrm{i}tX}\right) = \int_{-\infty}^{+\infty} \mathrm{e}^{\mathrm{i}tx} f_X(x)\mathrm{d}x,$$

则利用 Fourier 变换容易得到

$$f_X(x) = \frac{1}{2\pi}\int_{-\infty}^{+\infty} \mathrm{e}^{-\mathrm{i}tx}\psi_X(t)\mathrm{d}t.$$

特征函数显然满足

$$|\psi_X(t)| \leq \psi_X(0) = 1, \quad \psi_X(-t) = \psi_{-X}(t) = \overline{\psi_X(t)}.$$

注意到

$$|\psi_X(t+\Delta t) - \psi_X(t)| \leq \int_{-\infty}^{+\infty} \left|\mathrm{e}^{\mathrm{i}\Delta tx} - 1\right| \mathrm{d}F_X(x)$$

可知 $\psi_X(t)$ 一致连续.

Example 24. 用 $\delta_{x_0}(x)$ 表示在 x_0 一点处由 0 突越为 1 的分布函数, 相应的特征函数为 $\mathrm{e}^{\mathrm{i}x_0t}$. 进而对称 Bernoulli 分布

$$F(x) = \frac{1}{2}(\delta_{-1} + \delta_1)$$

的特征函数为

$$\psi(t)=\frac{1}{2}\left(\mathrm{e}^{-\mathrm{i}t}+\mathrm{e}^{\mathrm{i}t}\right)=\cos t.$$

0-1Bernoulli 分布

$$F(x)=(1-p)\delta_0+p\delta_1 \implies \psi(t)=1+p\left(\mathrm{e}^{\mathrm{i}t}-1\right).$$

几何分布

$$F(x)=\sum_{n=0}^{\infty}(1-p)^n p\delta_n \implies \psi(t)=\frac{p}{1-(1-p)\mathrm{e}^{\mathrm{i}t}}.$$

指数分布

$$f(x)=\lambda\mathrm{e}^{-\lambda x} \implies \psi(t)=\frac{\lambda}{\lambda-\mathrm{i}t}.$$

均匀分布

$$f(x)=\frac{1}{2a}(-a\le x\le a) \implies \psi(t)=\frac{\sin at}{at}.$$

正态分布

$$f(x)=\frac{1}{\sigma\sqrt{2\pi}}\exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right) \implies \psi(t)=\exp\left(\mathrm{i}\mu t-\frac{\sigma^2}{2}t^2\right).$$

Cauchy 分布

$$f(x)=\frac{a}{\pi(a^2+x^2)} \implies \psi(t)=\mathrm{e}^{-a|t|}.$$

Proposition 45. 设 $(\Omega,\mathscr{F},P)$ 是概率空间, X 是其上的随机变量, $\psi_X(t)$ 为相应的特征函数, 若 X 的 n 阶矩存在, 则可通过

$$E\left(X^n\right)=\mathrm{i}^{-n}\lim_{t\to 0}\frac{\mathrm{d}^n}{\mathrm{d}t^n}\psi_X(t)$$

计算.

Proof. 利用 Fourier 变换的求导特性

$$\frac{\mathrm{d}^n}{\mathrm{d}t^n}\int_{-\infty}^{+\infty}\mathrm{e}^{\mathrm{i}tx}\mathrm{d}F_X(x)=\int_{-\infty}^{+\infty}\mathrm{i}^n x^n\mathrm{e}^{\mathrm{i}tx}\mathrm{d}F_X(x).$$

由一致连续性

$$\lim_{t\to 0}\frac{\mathrm{d}^n}{\mathrm{d}t^n}\psi_X(t)=\mathrm{i}^n\int_{-\infty}^{+\infty}x^n\mathrm{d}F_X(x)=\mathrm{i}^n E\left(X^n\right).$$

□

Theorem 46.(Laha-Rohatgi) 设 $(\Omega,\mathscr{F},P)$ 是概率空间, X 是其上的随机变量, 概率分布函数为 $F(x)$, 相应的特征函数为 $\psi(t)$. 则对任意 $x_1<x_2$, 有

$$P(x_1<X<x_2)+\frac{P(X=x_1)+P(X=x_2)}{2}=\lim_{T\to+\infty}\frac{1}{2\pi}\int_{-T}^{T}\frac{\mathrm{e}^{-\mathrm{i}tx_1}-\mathrm{e}^{-\mathrm{i}tx_2}}{\mathrm{i}t}\psi(t)\mathrm{d}t.$$

Proof. 代入得极限号内是

$$\frac{1}{2\pi}\int_{-T}^{T}\int_{-\infty}^{+\infty}\frac{\mathrm{e}^{-\mathrm{i}tx_1}-\mathrm{e}^{-\mathrm{i}tx_2}}{\mathrm{i}t}\mathrm{e}^{\mathrm{i}tx}\mathrm{d}F(x)\mathrm{d}t.$$

被积函数有估计

$$\left|\frac{\mathrm{e}^{\mathrm{i}t(x-x_1)}-\mathrm{e}^{\mathrm{i}t(x-x_2)}}{\mathrm{i}t}\right|=\left|\int_{x_1}^{x_2}\mathrm{e}^{-\mathrm{i}tu}\mathrm{d}u\right|\leq\int_{x_1}^{x_2}\mathrm{d}u=x_2-x_1,$$

这表明原积分有估计

$$\frac{1}{2\pi}\int_{-T}^{T}\int_{-\infty}^{+\infty}(x_2-x_1)\mathrm{d}F(x)\mathrm{d}t=\frac{T}{\pi}(x_2-x_1)$$

收敛, 于是由 Fubini 定理可以换序为

$$\frac{1}{2\pi}\int_{-\infty}^{+\infty}\int_{-T}^{T}\frac{\mathrm{e}^{-\mathrm{i}tx_1}-\mathrm{e}^{-\mathrm{i}tx_2}}{\mathrm{i}t}\mathrm{e}^{\mathrm{i}tx}\mathrm{d}t\mathrm{d}F(x).$$

将指数展开为三角函数, 注意到积分区间对称, 只有偶函数部分非零, 于是内层积分即

$$\int_{-T}^{T}\frac{\mathrm{e}^{-\mathrm{i}tx_1}-\mathrm{e}^{-\mathrm{i}tx_2}}{\mathrm{i}t}\mathrm{e}^{\mathrm{i}tx}\mathrm{d}t=2\int_0^T\frac{\sin t(x-x_1)-\sin t(x-x_2)}{t}\mathrm{d}t.$$

为了进一步将极限号搬到积分内, 注意到上式有估计

$$\begin{aligned}\left|2\int_0^T\frac{\sin t(x-x_1)-\sin t(x-x_2)}{t}\mathrm{d}t\right|&\leq 2\left(\left|\int_0^T\frac{\sin t(x-x_1)}{t}\mathrm{d}t\right|+\left|\int_0^T\frac{\sin t(x-x_2)}{t}\mathrm{d}t\right|\right)\\&=2\left(\left|\int_0^{T(x-x_1)}\frac{\sin t}{t}\mathrm{d}t\right|+\left|\int_0^{T(x-x_2)}\frac{\sin t}{t}\mathrm{d}t\right|\right)\\&\leq 4\int_0^{\pi}\frac{\sin t}{t}\mathrm{d}t\end{aligned}$$

关于 T 一致有界, 于是根据有界收敛定理极限可交换, 右边变成

$$\frac{1}{\pi}\int_{-\infty}^{+\infty}\left(\lim_{T\to+\infty}\int_0^T\frac{\sin t(x-x_1)-\sin t(x-x_2)}{t}\mathrm{d}t\right)\mathrm{d}F(x).$$

根据 Dirichlet 核的性质, 内层积分取极限在 (x_1,x_2) 上结果为 π, 而在端点处为 $\pm\frac{\pi}{2}$, 外部为 0, 于是计算可得上式即

$$\int_{x_1<x<x_2}\mathrm{d}F(x)+\frac{1}{2}\int_{x=x_1,x=x_2}\mathrm{d}F(x),$$

也即

$$P(x_1<X<x_2)+\frac{P(X=x_1)+P(X=x_2)}{2}.$$

□

Corollary 47.(唯一性定理) 设 $(\Omega,\mathscr{F},P)$ 是概率空间, X,Y 是其上的随机变量, 则概率分布函数 $F_X(x)=F_Y(x)$ 当且仅当相应的特征函数 $\psi_X(t)=\psi_Y(t)$.

Proof. 根据特征函数的定义可知必要性. 注意到分布函数是单调函数, 因此其不连续点至多可数, 从而是 $\mathbb{R}$ 上的零测集, 进而端点连续的开区间 (x_1, x_2) 的生成 σ-代数恰好是 $\mathscr{B}_{\mathbb{R}}$. 根据**Theorem 46.**可知, 在这些区间上满足

$$F_X(x_2) - F_X(x_1) = F_Y(x_2) - F_Y(x_1),$$

进而生成的 σ-代数上也有分布函数相同. □

4.2 中心极限定理

Definition 38.(依分布收敛) 设 $(\Omega, \mathscr{F}, P)$ 是概率空间, X_n 是其上的随机变量序列, 相应的概率分布函数为 $F_n(x)$. 若随机变量 X 的分布函数 $F(x)$ 满足对任意 $x \in \mathbb{R}$ 是 $F(x)$ 的连续点, 都有

$$\lim_{n\to\infty} F_n(x) = F(x),$$

则称 X_n 依分布收敛 (dist.) 到 $F(x)$.

Remark. $F(x)$ 作为概率分布函数只有可数个不连续点, 从而在一个零测集上不连续, 因此以上的收敛都是非平凡的.

Definition 39.(holospoudic) 设 $(\Omega, \mathscr{F}, P)$ 是概率空间, X_n 是其上的随机变量序列, 若对任意 $\varepsilon > 0$, 都有

$$\lim_{n\to\infty} \max_{1\le k\le n} \{P(|X_k| > \varepsilon)\} = 0,$$

则称随机变量序列 $\{X_k\}$holospoudic.

Definition 40.(中心极限定理) 设 $(\Omega, \mathscr{F}, P)$ 是概率空间, X_n 是其上的随机变量序列, 记标准正态分布的概率分布函数为 $\Phi(x)$, 随机变量

$$S_n = \frac{\sum_{k=1}^{n} (X_k - E(X_n))}{\sqrt{\sum_{k=1}^{n} D(X_k)}}.$$

如果 S_n 依分布收敛到 $\Phi(x)$, 即对任意 $x \in \mathbb{R}$, 有

$$\lim_{n\to\infty} P\left(\frac{\sum_{k=1}^{n} (X_k - E(X_n))}{\sqrt{\sum_{k=1}^{n} D(X_k)}} \le x \right) = \Phi(x),$$

则称 $\{X_n\}$ 满足中心极限定理.

Theorem 48.(Levy) 设 $(\Omega, \mathscr{F}, P)$ 是概率空间, X_n 是其上独立同分布的随机变量序列, 则 $\{X_n\}$ 满足中心极限定理.

Proof. 设均值为 μ, 方差为 σ^2, 则相当于证明

$$\lim_{n\to\infty} P\left(\frac{\sum_{k=1}^{n} X_k - n\mu}{\sigma\sqrt{n}} \le x \right) = \Phi(x).$$

设 $X_n-\mu$ 的特征函数为 $\psi_X(t)$, 考虑随机变量 S_n 的特征函数

$$\psi_n(t)=E\left(\exp\left(\mathrm{i}tS_n\right)\right)=E\left(\exp\left(\mathrm{i}t\frac{X_k-\mu}{\sigma\sqrt{n}}\right)\right)^n.$$

注意到

$$\int_{-\infty}^{+\infty}\exp\left(\mathrm{i}t\frac{X_k-\mu}{\sigma\sqrt{n}}\right)\mathrm{d}F_X(x)=\int_{-\infty}^{+\infty}\exp\left(\mathrm{i}\frac{t}{\sigma\sqrt{n}}(X_k-\mu)\right)\mathrm{d}F_X(x)=\psi_X\left(\frac{t}{\sigma\sqrt{n}}\right),$$

作 Taylor 展开

$$\psi_X\left(\frac{t}{\sigma\sqrt{n}}\right)=\psi_X(0)+\frac{\mathrm{i}E(X_k-\mu)}{\sigma\sqrt{n}}t+\frac{\mathrm{i}^2E((X_k-\mu)^2)}{2\sigma^2n}t^2+o\left(\frac{t^2}{n}\right),$$

计算得

$$\psi_X\left(\frac{t}{\sigma\sqrt{n}}\right)=1-\frac{D(X_k-\mu)}{2\sigma^2n}t^2+o\left(\frac{t^2}{n}\right)=1-\frac{t^2}{2n}+o\left(\frac{t^2}{n}\right).$$

于是

$$\lim_{n\to\infty}\psi_n(t)=\lim_{n\to\infty}\left(1-\frac{t^2}{2n}+o\left(\frac{t^2}{n}\right)\right)^n=\exp\left(-\frac{t^2}{2}\right).$$

根据唯一性定理Corollary 47., 极限分布的特征函数是标准正态分布的特征函数, 表明极限分布就是标准正态分布 $\Phi(x)$. □

Theorem 49. 设复数列 $\{\theta_{nj}\}(1\le j\le k_n,n\ge 1)$ 满足

1. $\lim\limits_{n\to\infty}\max\limits_{1\le j\le k_n}\{|\theta_{nj}|\}=0$,
2. 对 $n\in\mathbb{N}^*$, 序列绝对和 $\sum\limits_{j=1}^{k_n}|\theta_{nj}|$ 一致有界 M,
3. $\lim\limits_{n\to\infty}\sum\limits_{j=1}^{k_n}\theta_{nj}=\theta$ 收敛,

则

$$\lim_{n\to\infty}\prod_{j=1}^{k_n}(1+\theta_{nj})=\mathrm{e}^{\theta}.$$

Proof. 每一项均可做展开

$$\log(1+\theta_{nj})=\theta_{nj}+\lambda_{nj}|\theta_{nj}|^2,$$

累加可得

$$\sum_{j=1}^{k_n}\log(1+\theta_{nj})-\theta=\left(\sum_{j=1}^{k_n}\theta_{nj}-\theta\right)+\sum_{j=1}^{k_n}\lambda_{nj}|\theta_{nj}|^2,$$

作估计

$$|\log(1+\theta_{nj})-\theta_{nj}|=\left|\sum_{m=2}^{\infty}\frac{(-1)^{m-1}}{m}\theta_{nj}^m\right|\le\sum_{m=2}^{\infty}\frac{|\theta_{nj}|^m}{m}.$$

注意 θ_{nj} 一致收敛于 0, 于是当 $n \geq n_0$ 充分大时, 有 $|\theta_{nj}| < \frac{1}{2}$, 于是进一步有

$$\sum_{m=2}^{\infty} \frac{|\theta_{nj}|^m}{m} \leq \frac{|\theta_{nj}|^2}{2} \sum_{m=2}^{\infty} \left(\frac{1}{2}\right)^{m-2} = |\theta_{nj}|^2,$$

这表明 λ_{nj} 有界 1. 作估计

$$\left|\sum_{j=1}^{k_n} \lambda_{nj}|\theta_{nj}|^2\right| \leq \max_{1\leq k\leq k_n}\{|\lambda_{nj}|\} \max_{1\leq k\leq k_n}\{|\theta_{nj}|\} \sum_{j=1}^{k_n} |\theta_{nj}| \leq M \max_{1\leq k\leq k_n}\{|\theta_{nj}|\},$$

因而由控制收敛可知收敛到 0. 在

$$\sum_{j=1}^{k_n} \log(1+\theta_{nj}) - \theta = \left(\sum_{j=1}^{k_n} \theta_{nj} - \theta\right) + \sum_{j=1}^{k_n} \lambda_{nj}|\theta_{nj}|^2$$

两边同时取极限即得

$$\lim_{n\to\infty} \sum_{j=1}^{k_n} \log(1+\theta_{nj}) = \theta \iff \lim_{n\to\infty} \prod_{j=1}^{k_n} (1+\theta_{nj}) = \mathrm{e}^{\theta}.$$

□

Theorem 50.(Liapounov) 设 $(\Omega, \mathscr{F}, P)$ 是概率空间, $X_{nj}(1 \leq j \leq k_n)$ 是其上的随机变量阵列, 其中当 $n \to \infty$ 有 $k_n \to \infty$, 各行内随机变量独立, 满足

$$\sum_{j=1}^{k_n} D(X_{nj}) = 1, \quad E(X_{nj}) = 0,$$

且 $E(|X_{nj}|^3)$ 有限存在, 以及

$$\lim_{n\to\infty} \sum_{j=1}^{k_n} E(|X_{nj}|^3) = 0,$$

则 $\{S_n\}$ 依分布收敛到 $\Phi(x)$, 其中 $S_n = \sum\limits_{j=1}^{k_n} X_{nj}$.

Proof. 为了应用**Theorem 49.**, 考虑 $\psi_{nj}(t)$ 的 Taylor 展开

$$\psi_{nj}(t) = 1 - \frac{1}{2}D(X_{nj})t^2 + \lambda_{nj}E(|X_{nj}|^3)|t|^3,$$

一次项为 0 是因为期望为 0, 对 Taylor 展开的余项估计可得 $|\lambda_{nj}| \leq \frac{1}{6}$. 取

$$\theta_{nj} = -\frac{1}{2}D(X_{nj})t^2 + \lambda_{nj}E(|X_{nj}|^3)|t|^3,$$

则

$$\max_{1\leq j\leq k_n}\{|\theta_{nj}|\} \leq \frac{t^2}{2} \max_{1\leq j\leq k_n}\{D(X_{nj})\} + \max_{1\leq j\leq k_n}\{|\lambda_{nj}|\} \max_{1\leq j\leq k_n}\left\{E(|X_{nj}|^3)\right\}|t|^3.$$

对期望的积分用 Jensen 不等式可得

$$\max_{1\le j\le k_n}\left\{E(X_{nj}^2)^{\frac{3}{2}}\right\},\max_{1\le j\le k_n}\left\{D(X_{nj})\right\}^{\frac{3}{2}}<\max_{1\le j\le k_n}\left\{E(|X_{nj}|^3)\right\}\le\sum_{j=1}^{k_n}E(|X_{nj}|^3),$$

而右边收敛到 0, 于是由控制收敛可知

$$\lim_{n\to\infty}\max_{1\le j\le k_n}\{|\theta_{nj}|\}=0.$$

另一方面

$$\sum_{j=1}^{k_n}|\theta_{nj}|\le\frac{t^2}{2}\sum_{j=1}^{k_n}D(X_{nj})+\frac{1}{6}\sum_{j=1}^{k_n}E(|X_{nj}|^3)|t|^3,$$

右边极限为 $\frac{t^2}{2}$ 有界. 最后

$$\left|\sum_{j=1}^{k_n}\theta_{nj}+\frac{t^2}{2}\right|\le\frac{1}{6}\sum_{j=1}^{k_n}E(|X_{nj}|^3)|t|^3$$

收敛到 0, 即

$$\lim_{n\to\infty}\sum_{j=1}^{k_n}\theta_{nj}=-\frac{t^2}{2}.$$

用**Theorem 49.**即得

$$\psi_n(t)=\prod_{j=1}^{k_n}\psi_{nj}(t)=\exp\left(-\frac{t^2}{2}\right),$$

根据唯一性定理**Corollary 47.**, 极限分布就是标准正态分布 $\Phi(x)$. □

Rermark. 以上给出的是标准化后的情形, 如果为进行标准化, 则要将 X_{nj} 变为

$$\frac{X_{nj}-E(X_{nj})}{\sqrt{\sum\limits_{j=1}^{k_n}D(X_{nj})}},$$

代入得 Liapounov 条件

$$\lim_{n\to\infty}\left(\sum_{j=1}^{k_n}D(X_{nj})\right)^{-\frac{3}{2}}\sum_{j=1}^{k_n}E(|X_{nj}-E(X_{nj})|^3)=0.$$

此时随机变量阵列不再有行内要求, 于是可以取 $X_j=X_{nj}$ 和 $k_n=n$, 使之成为随机变量序列, 即在条件

$$\lim_{n\to\infty}\left(\sum_{j=1}^{n}D(X_j)\right)^{-\frac{3}{2}}\sum_{j=1}^{n}E(|X_j-E(X_j)|^3)=0$$

下, 有 $\{X_n\}$ 满足中心极限定理.

Corollary 51. 设 $(\Omega, \mathscr{F}, P)$ 是概率空间, $X_{nj}(1 \leq j \leq k_n)$ 是其上的随机变量阵列, 其中当 $n \to \infty$ 有 $k_n \to \infty$, 各行内随机变量独立, 满足

$$\sum_{j=1}^{k_n} D(X_{nj}) = 1,$$

$|X_{nj}| \leq M_{nj}$ 有界几乎处处成立, 使得

$$\lim_{n\to\infty} \max_{1\leq j\leq k_n} \{M_{nj}\} = 0,$$

则 $\{S_n - E(S_n)\}$ 依分布收敛到 $\Phi(x)$, 其中 $S_n = \sum\limits_{j=1}^{k_n} X_{nj}$.

Proof. 我们证明**Theorem 50.**的条件. 注意到

$$\sum_{j=1}^{k_n} E(|X_{nj} - E(X_{nj})|^3) \leq 2 \max_{1\leq j\leq k_n} \{M_{nj}\} \sum_{j=1}^{k_n} D(X_{nj}) = 2 \max_{1\leq j\leq k_n} \{M_{nj}\}$$

收敛于 0 即可. □

Theorem 52.(Lindeberg-Feller) 设 $(\Omega, \mathscr{F}, P)$ 是概率空间, $X_{nj}(1 \leq j \leq k_n)$ 是其上的随机变量阵列, 其中当 $n \to \infty$ 有 $k_n \to \infty$, 各行内随机变量独立, 满足

$$\sum_{j=1}^{k_n} D(X_{nj}) = 1, \quad E(X_{nj}) = 0,$$

且对任意 $\varepsilon > 0$, 有

$$\lim_{n\to\infty} \sum_{j=1}^{k_n} \int_{|x|>\varepsilon} x^2 \mathrm{d}F_{nj}(x) = 0,$$

则随机变量序列 $\{X_n\}$holospoudic 且满足中心极限定理.

Proof. 由 Chebyshev 不等式的证明方法可得

$$P(|X_{nj}| > \varepsilon) \leq \frac{1}{\varepsilon^2} \int_{|x|>\varepsilon} x^2 \mathrm{d}F_{nj}(x) \leq \frac{1}{\varepsilon^2} \sum_{j=1}^{k_n} \int_{|x|>\varepsilon} x^2 \mathrm{d}F_{nj}(x),$$

于是其最大值被控制收敛到 0, 于是 holospoudic 满足. 考虑截断随机变量

$$Y_{nj} = \begin{cases} X_{nj}, & |X_{nj}| \leq \varepsilon, \\ 0, & \text{otherwise.} \end{cases}$$

记对 $1 \leq j \leq k_n$ 求和为 T_n, 则由于 $E(X_{nj}) = 0$, 有

$$E(Y_{nj}) = \int_{|x|\leq\varepsilon} x \mathrm{d}F_{nj}(x) = -\int_{|x|>\varepsilon} x \mathrm{d}F_{nj}(x).$$

从而

$$|E(Y_{nj})| \leq \int_{|x|>\varepsilon} |x| \mathrm{d}F_{nj}(x) \leq \frac{1}{\varepsilon} \int_{|x|>\varepsilon} x^2 \mathrm{d}F_{nj}(x),$$

求和即得

$$|E(T_n)| \leq \frac{1}{\varepsilon} \sum_{j=1}^{k_n} \int_{|x|>\varepsilon} x^2 \mathrm{d}F_{nj}(x)$$

控制收敛到 0. 根据 Cauchy-Schwarz 不等式有

$$E(Y_{nj})^2 \leq \int_{|x|>\varepsilon} x^2 \mathrm{d}F_{nj}(x) \int_{|x|>\varepsilon} \mathrm{d}F_{nj}(x) \leq \int_{|x|>\varepsilon} x^2 \mathrm{d}F_{nj}(x).$$

于是

$$D(Y_{nj}) = \int_{|x|\leq\varepsilon} x^2 \mathrm{d}F_{nj}(x) - E(Y_{nj})^2 \geq \int_{|x|\leq\varepsilon} x^2 \mathrm{d}F_{nj}(x) - \int_{|x|>\varepsilon} x^2 \mathrm{d}F_{nj}(x).$$

注意到

$$1 = D(S_n) \geq D(T_n) \geq \sum_{j=1}^{k_n} \int_{|x|\leq\varepsilon} x^2 \mathrm{d}F_{nj}(x) - \sum_{j=1}^{k_n} \int_{|x|>\varepsilon} x^2 \mathrm{d}F_{nj}(x)$$

取极限可知右边为 $1 - 0 = 1$, 于是

$$\lim_{n\to\infty} D(T_n) = 1, \quad \lim_{n\to\infty} E(T_n) = 0,$$

为了应用**Corollary 51.**的结果, 我们需要把截断 $|X_{nj}| \leq \varepsilon$ 变成动态截断 $|X_{nj}| \leq \varepsilon_n = M_{nj}$, 且使得 ε_n 的极限为 0. 为此考虑条件的推论

$$\lim_{n\to\infty} m^2 \sum_{j=1}^{k_n} \int_{|x|>\frac{1}{m}} x^2 \mathrm{d}F_{nj}(x) = 0,$$

于是可以选取适当的序列 ε_n 是某个 $\frac{1}{m}$, 使得

$$\lim_{n\to\infty} \frac{1}{\varepsilon_n^2} \sum_{j=1}^{k_n} \int_{|x|>\varepsilon_n} x^2 \mathrm{d}F_{nj}(x) = 0.$$

这样由**Corollary 51.**可知 $\frac{T_n - E(T_n)}{\sqrt{D(T_n)}}$ 依分布收敛到 $\Phi(x)$. 由依分布收敛的定义和 $E(T_n)$ 收敛到 0 可知 $\frac{T_n}{\sqrt{D(T_n)}}$ 依分布收敛到 $\Phi(x)$. 最后对 S_n 我们有

$$P(S_n \neq T_n) \leq P\left(\bigcup_{j=1}^{k_n} \{X_{nj} \neq Y_{nj}\}\right) \leq \sum_{j=1}^{k_n} P(|X_{nj}| > \varepsilon_n) \leq \sum_{j=1}^{k_n} \frac{1}{\varepsilon_n^2} \int_{|x|>\varepsilon_n} x^2 \mathrm{d}F_{nj}(x),$$

最后一个不等式是根据 holospoudic. 而右边收敛到 0, 于是再次由依分布收敛的定义可得 $\frac{S_n}{\sqrt{D(S_n)}}$ 依分布收敛到 $\Phi(x)$, 即随机变量序列 $\{X_n\}$ 满足中心极限定理. □

Rermark. 类似地, 我们有随机变量序列的版本. 设 $(\Omega, \mathscr{F}, P)$ 是概率空间, X_n 是其上的随机变量序列, 对任意 $\varepsilon > 0$, 有

$$\lim_{n\to\infty} \left(\sum_{k=1}^{n} D(X_k)\right)^{-1} \sum_{k=1}^{n} \int_{|x|>\varepsilon} (x - E(X_k))^2 \mathrm{d}F_k(x) = 0,$$

则随机变量序列 $\{X_n\}$holospoudic 且满足中心极限定理.

Chapter 5

问题

5.1 问题与解答

Problem 1.(取数问题) 从 $1, 2, \ldots, n$ 中随机选取 k 次, 将结果从小到大排列, 求可能的结果总数.

Solution. 这相当于在 k 个小球之间插 $n-1$ 个隔板, 分隔出 n 个区域, 第 t 个区域中小球的数目就是数字 t 被取出的次数. 因此结果为 C_{k+n-1}^{k}.

Problem 2.(Buffon 投针问题) 平面上有间距 a 的平行线, 随机选取一点作为针的中点, 随机选取一个角度 $\theta \in [0, \pi)$ 作为针的方向, 设针长 $l < a$, 求针与某条平行线相交的概率.

Solution. 不失一般性, 我们总是假设中心与最近的一条平行线距离为 $d \in \left[0, \frac{a}{2}\right]$. 根据操作在该区间的任何位置都是等概率的, 于是可设概率空间为

$$\Omega = [0, \pi) \times \left[0, \frac{a}{2}\right].$$

容易计算有交点当且仅当

$$0 \leq d \leq \frac{l}{2} \sin\theta,$$

于是事件发生的概率为

$$P = \frac{\int_0^{\pi} \frac{l}{2} \sin\theta}{\frac{a}{2} \cdot \pi} = \frac{2l}{\pi a}.$$

Problem 3.(最大似然估计问题) 给定 $a, b, m \in \mathbb{N}$, 求使得

$$P(n) = \frac{C_m^a C_{n-m}^b}{C_n^{a+b}}$$

取最大值的 $n \in \mathbb{N}$.

Solution. 若在 $n \in \mathbb{N}$ 处取最大值, 应当满足

$$P(n) \geq P(n-1), \quad P(n) \geq P(n+1).$$

解得

$$\frac{a+b}{a}m - 1 \leq n \leq \frac{a+b}{a}m.$$

于是

$$n = \begin{cases} \left[\frac{a+b}{a}m\right], & a \nmid bm, \\ \frac{a+b}{a}m \text{ or } \frac{a+b}{a}m - 1, & a \mid bm. \end{cases}$$

Problem 4.(集卡问题) 有 m 种样式不同的卡片, 随机抽取 $n \geq m$ 次, 求抽取全套卡片的概率.

Solution. 我们记 A_k 为事件 "这 n 次中抽出过第 k 种卡片". 容易发现

$$\Omega \setminus \bigcup_{j=1}^{k} A_{i_j}$$

是未抽到这 k 种卡片发生 n 次, 即

$$P\left(\Omega \setminus \bigcup_{j=1}^{k} A_{i_j}\right) = \left(1 - \frac{k}{m}\right)^n.$$

从而利用 De Morgan 定律和容斥原理

$$\begin{aligned} P\left(\bigcap_{k=1}^{m} A_k\right) &= 1 - P\left(\Omega \setminus \bigcap_{k=1}^{m} A_k\right) \\ &= 1 - P\left(\bigcup_{k=1}^{m} \Omega \setminus A_k\right) \\ &= 1 - \sum_{k=1}^{m} (-1)^{k-1} \sum_{1 \leq i_1 < i_2 < \cdots < i_k \leq m} P\left(\bigcap_{j=1}^{k} \Omega \setminus A_{i_j}\right) \\ &= 1 - \sum_{k=1}^{m} (-1)^{k-1} \sum_{1 \leq i_1 < i_2 < \cdots < i_k \leq m} P\left(\Omega \setminus \bigcup_{j=1}^{k} A_{i_j}\right) \\ &= 1 - \sum_{k=1}^{m} (-1)^{k-1} \sum_{1 \leq i_1 < i_2 < \cdots < i_k \leq m} \left(1 - \frac{k}{m}\right)^n \\ &= 1 + \sum_{k=1}^{m} (-1)^k C_m^k \left(1 - \frac{k}{m}\right)^n. \end{aligned}$$

Problem 5.(匹配问题) 有 n 个球和 n 个盒子一一对应, 现随机在每个盒子中放入一个小球, 求恰好没有一个球和盒子对应的概率. 并计算 $n \to \infty$ 时概率的极限.

Solution. 我们记 A_k 为事件 “第 k 个盒子中的球恰好对应”. 容易发现

$$\bigcap_{j=1}^{k} A_{i_j}$$

是这 k 个盒子对应, 其余盒子任意, 即

$$P\left(\bigcap_{j=1}^{k} A_{i_j}\right) = \frac{(n-k)!}{n!}.$$

从而利用 De Morgan 定律和容斥原理

$$\begin{aligned}
P\left(\bigcap_{k=1}^{n} \Omega \setminus A_k\right) &= 1 - P\left(\bigcup_{k=1}^{n} A_k\right) \\
&= 1 - \sum_{k=1}^{n} (-1)^{k-1} \sum_{1\le i_1<i_2<\cdots<i_k\le n} P\left(\bigcap_{j=1}^{k} A_{i_j}\right) \\
&= 1 - \sum_{k=1}^{n} (-1)^{k-1} \sum_{1\le i_1<i_2<\cdots<i_k\le n} \frac{(n-k)!}{n!} \\
&= 1 + \sum_{k=1}^{n} (-1)^{k} C_n^k \frac{(n-k)!}{n!} \\
&= \sum_{k=0}^{n} (-1)^{k} \frac{1}{k!}.
\end{aligned}$$

当 $n \to \infty$ 时, 上式即

$$\sum_{k=0}^{\infty} (-1)^{k} \frac{1}{k!} = \mathrm{e}^{-1}.$$

Problem 6.(Banach 火柴问题) 两盒火柴初始都有 n 根, 每次随机选一盒拿走一根, 一旦一盒取完则停止, 求停止时另一盒恰剩下 r 根的概率.

Solution. 设两盒火柴为 A 盒和 B 盒, 则可认为每次抽火柴盒是一个 Bernoulli 试验, 成功表示取 A 盒, 失败表示取 B 盒. 则满足题给条件只有两种情况, 即在 $2n-r$ 次试验中成功 n 次, 且最后一次成功, 或者失败 n 次, 且最后一次失败. 于是概率为

$$P = C_{2n-r-1}^{n-1} \left(\frac{1}{2}\right)^{n} \left(\frac{1}{2}\right)^{n-r-1} \left(\frac{1}{2}\right) + C_{2n-r-1}^{n-r} \left(\frac{1}{2}\right)^{n-r-1} \left(\frac{1}{2}\right)^{n} \left(\frac{1}{2}\right) = \frac{C_{2n-r-1}^{n-1}}{2^{2n-r-1}}.$$

Problem 7.(随机游走问题) 一点在数直线上从 0 开始随机游走, 向右的概率为 $p \in (0,1)$, 向左的概率为 $q = 1-p$. 随机变量 X_n 表示 n 时刻该点的位置, 计算 $P(X_n = k)$. 进一步设 $a, b \in \mathbb{N}^*$, 一旦该点到达 $-a$ 或 b 即终止游走, 证明: 该点终止在 $-a$ 的概率为

$$p_a = \begin{cases} \frac{1-\left(\frac{p}{q}\right)^{b}}{1-\left(\frac{p}{q}\right)^{a+b}}, & p \neq q, \\ \frac{b}{a+b}, & p = q. \end{cases}$$

Proof. $X_n = k$ 当且仅当完成 $\frac{n+k}{2}$ 次向右和 $\frac{n-k}{2}$ 次向左. 当 $n \not\equiv k \pmod 2$ 时, 以上无定义, 从而概率为 0, 否则相当于进行 n 次 Bernoulli 试验, 从而

$$P(X_n = k) = \begin{cases} C_n^{\frac{n+k}{2}} p^{\frac{n+k}{2}} q^{\frac{n-k}{2}}, & n \not\equiv k \pmod 2, \\ 0, & n \equiv k \pmod 2. \end{cases}$$

采用递推方法, 设事件 A_k 为点初始在 t 处, 最终终止在 $-a$, 则直接有 $P(A_{-a}) = 1$ 和 $P(A_b) = 0$. 由于下一步只能向左或向右, 于是对 $-a < t < b$, 有

$$P(A_t) = pP(A_{t+1}) + qP(A_{t-1}).$$

移项有

$$p(P(A_{t+1}) - P(A_t)) = q(P(A_t) - P(A_{t-1})).$$

若 $p = q$, 则 $P(A_{t+1}) - P(A_t)$ 是常数 c, 进而

$$(a+b)c = P(A_b) - P(A_{-a}) = 1 \implies p_a = P(A_0) = 1 - ac = \frac{b}{a+b}.$$

若 $p \neq q$, 设 $P(A_{-a+1}) - P(A_{-a}) = c$, 解得

$$P(A_t) = \left(1 + \frac{q}{p} + \cdots + \left(\frac{q}{p}\right)^{a+t-1}\right) c + P(A_{-a}).$$

代入 $P(A_{-a}) = 1$ 和 $P(A_b) = 0$ 得

$$c = \frac{P(A_b) - P(A_{-a})}{\left(1 + \frac{q}{p} + \cdots + \left(\frac{q}{p}\right)^{a+b-1}\right)} = -\frac{1 - \frac{q}{p}}{1 - \left(\frac{q}{p}\right)^{a+b}}.$$

进而

$$P(A_0) = -\left(1 + \frac{q}{p} + \cdots + \left(\frac{q}{p}\right)^{a-1}\right) \frac{1 - \frac{q}{p}}{1 - \left(\frac{q}{p}\right)^{a+b}} + 1 = 1 - \frac{1 - \left(\frac{q}{p}\right)^{a}}{1 - \left(\frac{q}{p}\right)^{a+b}}.$$

即得

$$p_a = \frac{1 - \left(\frac{p}{q}\right)^{b}}{1 - \left(\frac{p}{q}\right)^{a+b}}.$$

□

5.2 习题集

Exercise 1.(Chebyshev 不等式) 设随机变量 X 的概率密度函数为

$$f(x)=\frac{x^m}{m!}\mathrm{e}^{-x},\quad x\geq 0.$$

证明

$$P(0<X<2(m+1))\geq\frac{m}{m+1}.$$

Proof. 首先计算这一分布的特征函数. 利用分部积分法, 期望

$$E(X)=\int_0^{+\infty}x\frac{x^m}{m!}\mathrm{e}^{-x}\mathrm{d}x=-\int_0^{+\infty}\frac{x^{m+1}}{m!}\mathrm{d}\mathrm{e}^{-x}=\frac{1}{m!}(m+1)\int_0^{+\infty}x^m\mathrm{e}^{-x}\mathrm{d}x=m+1.$$

同样有

$$E\left(X^2\right)=\int_0^{+\infty}x^2\frac{x^m}{m!}\mathrm{e}^{-x}\mathrm{d}x=\frac{1}{m!}(m+2)!=(m+2)(m+1).$$

于是方差

$$D(X)=E\left(X^2\right)-E(X)^2=m+1.$$

因此

$$P(0<X<2(m+1))=P(-D(X)<X-E(X)<D(X)).$$

于是在 Chebyshev 不等式中取 $\alpha=2$ 和 $\varepsilon=D(X)$, 即得

$$P(|X-E(X)|\geq D(X))\leq\frac{1}{D(X)}=\frac{1}{m+1},$$

两边用 1 减即得

$$P(0<X<2(m+1))\geq\frac{m}{m+1}.$$

□

Exercise 2.(Poisson 分布) 设随机变量 X 表示进行实验的次数, 服从参数为 λ 的 Poisson 分布, 即

$$P(X=k)=\frac{\lambda^k}{k!}\mathrm{e}^{-\lambda}.$$

每次实验彼此独立且独立于 X, 成功率为 p. 设随机变量 Y 表示实验成功的次数, 求其分布, 期望与方差.

Solution. 根据全概率公式

$$P(Y=m)=\sum_{n=m}^{\infty}P(Y=m\mid X=n)P(X=n).$$

在条件 $X=n$, 即进行 n 次实验, 则成功 m 次的概率为二项分布

$$P(Y=m\mid X=n)=C_n^m p^m(1-p)^{n-m}.$$

于是

$$\begin{aligned}P(Y=m) &= \sum_{n=m}^{\infty} C_n^m p^m (1-p)^{n-m} \frac{\lambda^n}{n!} \mathrm{e}^{-\lambda} \\ &= \sum_{n=m}^{\infty} \frac{n!}{m!(n-m)!} p^m (1-p)^{n-m} \frac{\lambda^n}{n!} \mathrm{e}^{-\lambda} \\ &= \sum_{n=m}^{\infty} \frac{1}{m!(n-m)!} p^m (1-p)^{n-m} \lambda^m \lambda^{n-m} \mathrm{e}^{-\lambda} \\ &= \frac{(p\lambda)^m}{m!} \mathrm{e}^{-\lambda} \sum_{n=m}^{\infty} \frac{(\lambda(1-p))^{n-m}}{(n-m)!}.\end{aligned}$$

这恰好是 e^x 的 Taylor 展开式, 从而

$$P(Y=m) = \frac{(p\lambda)^m}{m!} \mathrm{e}^{-\lambda} \mathrm{e}^{\lambda(1-p)} =$$

$$P(Y=m) = \frac{(p\lambda)^m}{m!} \mathrm{e}^{-\lambda} \mathrm{e}^{\lambda(1-p)} = \frac{(p\lambda)^m}{m!} \mathrm{e}^{-p\lambda},$$

即服从参数为 $p\lambda$ 的 Poisson 分布. 计算数学期望

$$E(Y) = \sum_{m=0}^{\infty} m \frac{(p\lambda)^m}{m!} \mathrm{e}^{-p\lambda} = p\lambda \mathrm{e}^{-p\lambda} \sum_{m=1}^{\infty} \frac{(p\lambda)^{m-1}}{(m-1)!} = p\lambda \mathrm{e}^{-p\lambda} \mathrm{e}^{p\lambda} = p\lambda.$$

类似地

$$E\left(Y^2\right) - E(Y) = \sum_{m=0}^{\infty} m(m-1) \frac{(p\lambda)^m}{m!} \mathrm{e}^{-p\lambda} = (p\lambda)^2 \mathrm{e}^{-p\lambda} \sum_{m=2}^{\infty} \frac{(p\lambda)^{m-2}}{(m-2)!} = p^2\lambda^2,$$

于是

$$D(Y) = E\left(Y^2\right) - E(Y)^2 = p^2\lambda^2 + p\lambda - (p\lambda)^2 = p\lambda.$$

Exercise 3.(几何分布) 设 $(\Omega, \mathscr{F}, P)$ 为概率空间, $X : \Omega \to \mathbb{N}$ 为其上的离散型随机变量, 使得 $P(X=1) \in (0,1)$. 证明: X 服从几何分布的充要条件为对任意 $m, n \in \mathbb{N}$, 有

$$P(X > m+n) = P(X > m)P(X > n).$$

Proof. (必要性) 计算

$$P(X > n) = p \sum_{k=n+1}^{\infty} (1-p)^{k-1} = p \frac{(1-p)^n}{1-(1-p)} = (1-p)^n.$$

于是

$$P(X > m+n) = (1-p)^{m+n} = (1-p)^m (1-p)^n = P(X > m)P(X > n).$$

(充分性) 记 $a = P(X > 1)$, 则

$$P(X > n+1) = P(X > n)P(X > 1) = aP(X > n).$$

归纳可得 $P(X>n)=a^n$, 于是 $P(X=n)=a^{n-1}(1-a)$ 对任意 $n\in\mathbb{N}^*$. 再代入 $m=n=0$, 根据 $P(X=1)\in(0,1)$ 可知

$$P(X>0)=P(X>0)^2 \implies P(X>0)=1 \implies P(X=0)=0.$$

于是令 $a=1-p$ 即得

$$P(X=n)=p(1-p)^{n-1}.$$

□

Exercise 4.(随机变量函数) 设随机变量 X 服从 $\left(-\frac{1}{2},\frac{1}{2}\right)$ 上的均匀分布. 可测函数

$$\varphi(x)=\begin{cases}0, & x\le 0,\\ \ln x, & x>0.\end{cases}$$

求随机变量 $Y=\varphi(X)$ 的分布函数, 数学期望和方差.

Solution. 容易写出连续型随机变量 X 的分布函数

$$F_X(x)=\begin{cases}0, & x\le -\frac{1}{2},\\ x+\frac{1}{2}, & -\frac{1}{2}<x<\frac{1}{2},\\ 1, & x\ge\frac{1}{2}.\end{cases}$$

设 Y 的分布函数为 $F_Y(x)$, 则当 $x\ge 0$ 时, 有

$$F_Y(x)=P(Y\le x)=P(Y\in\mathbb{R})=1.$$

注意到 $x=\frac{1}{2}$ 时, $\varphi(x)=-\ln 2$, 当 $-\ln 2\le x<0$ 时, 有

$$F_Y(x)=P(Y\le x)=P(\ln X\le x)=P(0<X\le \mathrm{e}^x)=F_X(\mathrm{e}^x)-F_X(0)=1-\frac{1}{2}=\frac{1}{2}.$$

最后, 当 $x<-\ln 2$ 时, 有

$$F_Y(x)=P(0<X\le \mathrm{e}^x)=F_X(\mathrm{e}^x)-F_X(0)=\mathrm{e}^x+\frac{1}{2}-\frac{1}{2}=\mathrm{e}^x.$$

因此分布函数

$$F_Y(x)=\begin{cases}\mathrm{e}^x, & x<-\ln 2,\\ \frac{1}{2}, & -\ln 2\le x<0,\\ 1, & x\ge 0.\end{cases}$$

期望有两种方法计算. 一种是根据定义

$$E(Y)=\int_{-\infty}^{-\ln 2}x\mathrm{d}\mathrm{e}^x+\int_{-\ln 2}^{0}x\mathrm{d}\frac{1}{2}+\int_0^{+\infty}x\mathrm{d}0=(x-1)\mathrm{e}^x\Big|_{-\infty}^{-\ln 2}=-\frac{1+\ln 2}{2}.$$

另一种是利用**Proposition 21.**给出的公式

$$E(Y)=\int_{-\infty}^{+\infty}\varphi(x)\mathrm{d}F_X(x)=\int_0^{\frac{1}{2}}\ln x\mathrm{d}x=(x-1)\ln x\Big|_0^{\frac{1}{2}}=-\frac{1+\ln 2}{2}.$$

类似地

$$E\left(Y^2\right)=\int_0^{\frac{1}{2}}\ln^2 x\mathrm{d}x=x\ln^2 x\Big|_0^{\frac{1}{2}}-2\int_0^{\frac{1}{2}}\ln x\mathrm{d}x=\frac{\ln^2 2}{2}+\frac{1+\ln 2}{2}.$$

于是方差

$$D(X)=E\left(Y^2\right)-E(Y)^2=\frac{\ln^2 2+2\ln 2+3}{4}.$$

Exercise 5.(累计均匀分布) 设 $(\Omega,\mathscr{F},P)$ 为概率空间, $\{X_n\}$ 为独立同均匀分布 $U(0,1)$ 的无穷随机变量序列. 对每个 $0\leq x\leq 1$, 定义随机变量

$$N(x)=\min\left\{n\in\mathbb{N}^*\mid\sum_{k=1}^{n}X_k>x\right\},$$

证明 $E(N(x))=\mathrm{e}^x$.

Proof. 先考虑

$$P(N(x)\geq n+1)=1-P(N(x)\leq n).$$

在 $[0,1]^n$ 上, $P(N(x)\leq n)$ 代表了区域

$$A=\left\{\mathbf{x}\in[0,1]^n\mid\sum_{k=1}^{n}x_k>x\right\}.$$

其余集的体积 (概率) 为

$$\int_0^x\mathrm{d}x_{n-1}\int_0^{x_{n-1}}\mathrm{d}x_{n-1}\cdots\int_0^{x_1}\mathrm{d}x_0=\frac{x^n}{n!}.$$

于是根据**Proposition 20.**有

$$E(N(x))=\sum_{n=0}^{\infty}P(N(x)\geq n+1)=\sum_{n=0}^{\infty}\frac{x^n}{n!}=\mathrm{e}^x.$$

□

Exercise 6.(正态分布的顺序统计量) 设随机变量 X,Y 服从二元正态分布

$$f(x,y)=\frac{1}{2\pi\sqrt{1-\rho^2}}\exp\left(-\frac{x^2-2\rho xy+y^2}{2(1-\rho^2)}\right).$$

证明:

$$E(\max\{X,Y\})=\sqrt{\frac{1-\rho}{\pi}},\quad E(\min\{X,Y\})=-\sqrt{\frac{1-\rho}{\pi}}.$$

Proof. 我们计算 $\max\{X,Y\}$ 的分布函数

$$F(z)=P(\max\{X,Y\}\le z)=\int_{-\infty}^{z}\int_{-\infty}^{z}f(x,y)\mathrm{d}x\mathrm{d}y.$$

由于积分一致收敛, 从而可以求导

$$f(z)=F'(z)=2\int_{-\infty}^{z}f(z,y)\mathrm{d}y.$$

依照期望的定义只要计算

$$E(\max\{X,Y\})=\int_{-\infty}^{+\infty}z\left(2\int_{-\infty}^{z}\frac{1}{2\pi\sqrt{1-\rho^2}}\exp\left(-\frac{z^2-2\rho zy+y^2}{2(1-\rho^2)}\right)\mathrm{d}y\right)\mathrm{d}z.$$

对区域更换积分顺序得

$$\frac{1}{\pi\sqrt{1-\rho^2}}\int_{-\infty}^{+\infty}\left(\int_{y}^{+\infty}z\exp\left(-\frac{z^2-2\rho zy+y^2}{2(1-\rho^2)}\right)\mathrm{d}z\right)\mathrm{d}y.$$

记系数右边的二重积分结果为 I, 利用**Example 23.**中的一些计算公式可得

$$\int_{y}^{+\infty}\frac{z-\rho y}{1-\rho^2}\exp\left(-\frac{z^2-2\rho zy+y^2}{2(1-\rho^2)}\right)\mathrm{d}z=\exp\left(-\frac{y^2}{1+\rho}\right),$$

于是可得

$$I=(1-\rho^2)\int_{-\infty}^{+\infty}\exp\left(-\frac{y^2}{1+\rho}\right)\mathrm{d}y+\rho\int_{-\infty}^{+\infty}\left(y\int_{y}^{+\infty}\exp\left(-\frac{z^2-2\rho zy+y^2}{2(1-\rho^2)}\right)\mathrm{d}z\right)\mathrm{d}y.$$

根据 Gauss 积分第一项就是

$$(1-\rho^2)\sqrt{\pi(1+\rho)},$$

而第二项与 ρI 的和恰好是

$$\int_{-\infty}^{+\infty}\left(y\int_{-\infty}^{+\infty}\exp\left(-\frac{z^2-2\rho zy+y^2}{2(1-\rho^2)}\right)\mathrm{d}z\right)\mathrm{d}y,$$

利用**Example 23.**中的计算公式可以求出内层积分

$$\int_{-\infty}^{+\infty}y\sqrt{2\pi(1-\rho^2)}\exp\left(-\frac{y^2}{2}\right)\mathrm{d}y=0,$$

这就说明

$$I=(1-\rho^2)\sqrt{\pi(1+\rho)}-\rho I\implies I=(1-\rho)\sqrt{\pi(1+\rho)}.$$

于是

$$E(\max\{X,Y\})=\frac{(1-\rho)\sqrt{\pi(1+\rho)}}{\pi\sqrt{1-\rho^2}}=\sqrt{\frac{1-\rho}{\pi}}.$$

同理可证

$$E(\min\{X,Y\})=-\sqrt{\frac{1-\rho}{\pi}}.$$

□

Exercise 7.(随机变量长度序列) 给定正整数 $n \in \mathbb{N}^*$, 设随机变量 N 服从参数为 n 的 Possion 分布, 即

$$P(N=m)=\frac{n^m}{m!}\mathrm{e}^{-n}, \quad m \in \mathbb{N}.$$

随机变量 $X_k(1 \leq k \leq n)$ 表示在 $(0,1]$ 上随机取 N 个点中落在

$$\left(\frac{k-1}{n}, \frac{k}{n}\right]$$

中点的个数, X_k 与 N 均独立. 证明: $X_1, X_2, \ldots, X_n$ 独立.

Proof. 利用全概率公式展开

$$P\left(\bigcap_{k=1}^{n}(X_k=x_k)\right)=\sum_{m=0}^{\infty} P\left(\bigcap_{k=1}^{n}(X_k=x_k) \mid N=m\right) P(N=m).$$

第一项是 m 个点所有符合条件的取法除上所有可能的取法, 即

$$P\left(\bigcap_{k=1}^{n}(X_k=x_k) \mid N=m\right)=\frac{m!}{n^m \prod\limits_{k=1}^{n} x_k!}.$$

于是代入计算

$$\sum_{m=0}^{\infty} \frac{m!}{n^m \prod\limits_{k=1}^{n} x_k!} \frac{n^m}{m!}\mathrm{e}^{-n}=\sum_{m=0}^{\infty} \frac{1}{\prod\limits_{k=1}^{n} x_k!}\mathrm{e}^{-n}.$$

注意此式只有

$$m=\sum_{k=1}^{n} x_k$$

时有意义, 其他情况取值为 0, 于是

$$P\left(\bigcap_{k=1}^{n}(X_k=x_k)\right)=\frac{\mathrm{e}^{-n}}{\prod\limits_{k=1}^{n} x_k!}.$$

类似地有

$$\begin{aligned}
P\left(X_k=x_k\right) &= \sum_{m=x_k}^{\infty} P\left(X_k=x_k \mid N=m\right) P(N=m) \\
&= \sum_{m=x_k}^{\infty} C_m^{x_k}\left(\frac{1}{n}\right)^{x_k}\left(1-\frac{1}{n}\right)^{m-x_k} \frac{n^m}{m!}\mathrm{e}^{-n} \\
&= \frac{\mathrm{e}^{-n}}{x_k!} \sum_{m=x_k}^{\infty} \frac{(n-1)^{m-x_k}}{(m-x_k)!} \\
&= \frac{\mathrm{e}^{-n}}{x_k!}\mathrm{e}^{n-1} \\
&= \frac{\mathrm{e}^{-1}}{x_k!}.
\end{aligned}$$

于是立即得到

$$P\left(\bigcap_{k=1}^{n}(X_k = x_k)\right) = \prod_{k=1}^{n} P(X_k = x_k),$$

这就说明 $X_1, X_2, \ldots, X_n$ 独立. □

Exercise 8.(顺序统计量的乘积期望) 设随机变量 N 服从

$$P(N = n) = \frac{1}{(\mathrm{e} - 2)(n+1)!}, \quad n \in \mathbb{N}^*.$$

随机变量 $X_k (1 \leq k \leq N)$ 独立同分布 $U(0,1)$, 且与 N 均独立. 记随机变量

$$\min = \min_{1 \leq k \leq N} \{X_k\}, \quad \max = \max_{1 \leq k \leq N} \{X_k\},$$

求期望 $E(\min \max)$ 的值.

Solution. 采用条件期望的全概率公式

$$E(\min \max) = \sum_{n=1}^{\infty} E(\min \max \mid N = n) P(N = n)$$

对每个固定的 n, 独立同分布随机变量的顺序统计量可以求得

$$F_{\min,\max}(x, y) = P(\min \leq x \cap \max \leq y) = P(\max \leq y) - P(\min > x \cap \max \leq y).$$

由 min 和 max 的定义和独立性有

$$P(\max \leq y) = P\left(\bigcap_{k=1}^{n}(X_k \leq y)\right) = F(y)^n,$$

于是

$$F_{\min,\max}(x, y) = y^n - (y - x)^n.$$

对各个分量求偏导可得

$$f_{\min,\max}(x, y) = n(n-1)(y - x)^{n-2}.$$

于是期望在 $0 \leq \min \leq \max \leq 1$ 上有值, 即

$$E(\min \max \mid N = n) = \int_0^1 \mathrm{d}y \int_0^y xy f_{\min,\max}(x, y) \mathrm{d}x = \frac{1}{n+2}.$$

代入得

$$E(\min \max) = \sum_{n=1}^{\infty} \frac{1}{n+2} \frac{1}{(\mathrm{e} - 2)(n+1)!} = \frac{1}{\mathrm{e} - 2} \sum_{n=1}^{\infty} \frac{1}{(n+2)!} = \frac{\mathrm{e} - 1 - 1 - \frac{1}{2}}{\mathrm{e} - 2} = \frac{\mathrm{e} - \frac{5}{2}}{\mathrm{e} - 2}.$$